Aprendizado de máquina para estratificação de risco de morte súbita cardíaca a partir do Holter de 24 horas

Defesa de dissertação de mestrado

Daniel Oliveira dos Santos

Orientador: Prof. Dr. João Paulo do Vale Madeiro

Coorientador: Prof. José Maria da Silva Monteiro Filho

5 de novembro de 2026

Programa de Pós-Graduação em Ciência da Computação (MDCC)
Universidade Federal do Ceará

Roteiro

1. Introdução
2. Trabalhos relacionados
3. Fundamentação teórica
4. Metodologia
5. Resultados
6. Conclusões

Morte súbita cardíaca: quando o coração para sem aviso

Na insuficiência cardíaca, a morte chega por duas vias: a **falência de bomba**, lenta e progressiva, e a **morte súbita cardíaca (MSC)**, abrupta.

O que é	**Quanto pesa**	**Como se previne**
evento abrupto, em geral por arritmia ventricular, em paciente muitas vezes estável	cerca de **metade** das mortes na insuficiência cardíaca (TOMASELLI; ZIPES, 2004)	cardiodesfibrilador implantável, indicado pela fração de ejeção (FEVE) (BARDY et al., 2005)

O que esses fatos têm em comum?

A MSC nasce de uma **falha elétrica** do coração — e é justamente a atividade elétrica que o ECG registra. O Holter de 24 horas, que a acompanha por um dia inteiro, já guardaria sinais desse risco?

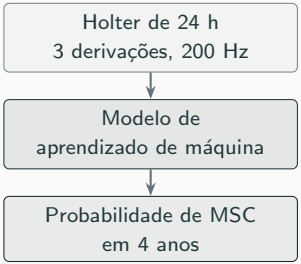
O que queremos prever?

A probabilidade de MSC em quatro anos

- Para cada paciente, um **risco individual**, e não um sim ou não por limiar.
- Permite ordenar os pacientes e concentrar a prevenção em quem mais precisa.

A partir do Holter de 24 horas

- Exame não invasivo, barato e amplamente disponível.
- Registra ectopias, pausas e a variação da frequência entre sono e vigília.



Por que a fração de ejeção não basta

Hoje, a decisão de implantar o cardiodesfibrilador depende basicamente de **um único número**: a FEVE abaixo de um limiar (ZEPPENFELD et al., 2022).

Quem recebe o dispositivo

Muitos pacientes nunca chegam a utilizá-lo: o critério indica pessoas que não teriam a arritmia.

Quem fica de fora

Parte das mortes súbitas ocorre com FEVE **acima** do limiar: o critério não alcança esses pacientes.

Por que isso importa

Há espaço para ferramentas que **estratifiquem melhor** o risco de MSC — e o ECG, que mede diretamente a atividade elétrica, é um candidato natural.

Como a literatura tem abordado o problema

Os trabalhos se organizam em duas frentes, raramente comparadas entre si:

Marcadores definidos por especialistas

- VFC, ectopia, turbulência, repolarização.
- Combinados com variáveis clínicas em modelos estatísticos.
- Na base MUSIC: (RAMÍREZ et al., 2017; SWEE et al., 2026).

Redes profundas sobre o sinal

- Sucesso no **diagnóstico** de arritmias (HANNUN et al., 2019; RIBEIRO et al., 2020).
- Na **predição** de eventos, os melhores resultados usaram redes pré-treinadas em grandes bases (KIM et al., 2025).

Prever não é diagnosticar

O evento ocorre meses ou anos depois do exame, e as coortes têm poucas centenas de pacientes.

Objetivo e contribuição deste trabalho

Objetivo geral

Investigar métodos de aprendizado de máquina e de pré-processamento do ECG para prever a MSC em pacientes com insuficiência cardíaca crônica, a partir do Holter de 24 horas, em quatro anos de acompanhamento.

Três lacunas motivam o trabalho:

1. **falta de comparação direta**: cada estudo avaliou uma única abordagem, em coortes e protocolos diferentes;
2. **avaliação otimista**: métricas por trecho do sinal e seleção de variáveis com o desfecho de toda a coorte (KAPOOR; NARAYANAN, 2023);
3. **fibrilação atrial na coorte**, que pode inflar a discriminação.

Contribuição: três cenários nos mesmos 517 pacientes

I. redes profundas sobre o sinal bruto; **II.** marcadores extraídos do ECG com aprendizado de máquina clássico; **III.** variáveis clínicas, isoladas e combinadas ao ECG — com avaliação por paciente e em ritmo sinusal.

Na coorte MUSIC: marcadores do ECG e variáveis clínicas

Ramírez et al. (2017)

- 597 pacientes em ritmo sinusal, 49 mortes súbitas.
- Marcadores da repolarização e turbulência + clínicos, em modelo de Cox.
- AUC de 0,73 na FEVE reduzida, **sem validação separada**.

Swee et al. (2026)

- 746 pacientes, **sem restrição de ritmo**, derivação Y.
- Marcadores de segmentos de 30 s; sequência processada por rede convolucional temporal (múltiplas instâncias).
- AUC de 0,682 $\pm$ 0,030 apenas com o ECG (média entre partições).

Redes profundas no Holter, e onde este trabalho se encaixa

Kim et al. (2025)

- 1 108 pacientes (infarto ou insuficiência cardíaca), 70 eventos.
- Codificador pré-treinado e congelado; só um classificador pequeno é ajustado.
- AUC de 0,74 na coorte completa, mas **0,60** no subgrupo com insuficiência cardíaca.

Este trabalho

- Três abordagens no **mesmo protocolo** e nos mesmos pacientes.
- Controle do otimismo: avaliação por paciente, seleção dentro da partição, intervalos de confiança.
- Restrição ao **ritmo sinusal**.

Antes de analisar: limpar o sinal do ECG

- **Interferências**: oscilação de linha de base ($<$ 0,5 Hz), ruído muscular, rede elétrica (50 Hz).
- **Filtro passa-faixa** Butterworth 0,5–40 Hz, aplicado nos dois sentidos (fase nula).
- **Normalização** da amplitude por derivação.
- **Janelas**: o registro de 24 h é dividido em trechos; janelas de um mesmo paciente **não são independentes**.



10 s de Holter, derivações X, Y e Z, após o filtro.

O que extraímos do ECG: ritmo, ectopia e morfologia

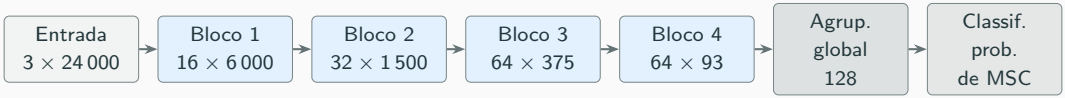
- **Detecção do QRS** e delineação das ondas (NeuroKit2 (MAKOWSKI et al., 2021)).
- **Intervalos RR e NN**: NN = entre batimentos normais.
- **VFC**: SDNN, RMSSD, pNN50, potências LF e HF, Poincaré (SD1, SD2), entropia amostral.
- **Morfologia**: QRS, QT, QTc, ondas P e T.
- **Ectopia**: extrassístoles, dupletes, pausas.

Medida	5 min	30 s
Domínio do tempo	sim	sim
LF, HF, LF/HF	sim	não
Entropia amostral	sim	não
Morfologia	sim	sim
Contagens de ectopia	sim	sim

A duração do segmento limita quais medidas são confiáveis.

Redes convolucionais: aprender padrões direto do sinal

- **Convolução 1D**: filtros que deslizam no tempo e detectam padrões locais (núcleo de 75 ms $\approx$ um QRS).
- Cada bloco: convolução $\rightarrow$ normalização em lote $\rightarrow$ ReLU $\rightarrow$ agrupamento máximo $\rightarrow$ descarte.
- **Agrupamento global** (média e máximo) e classificador.
- Perda: entropia cruzada ponderada, $w_{+} = N_0/N_1 \approx 8{,}4$.

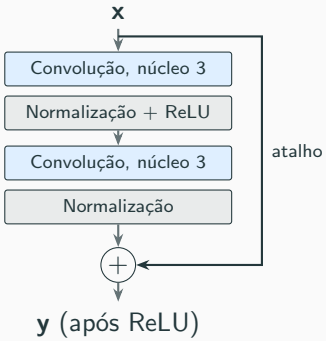


Redes residuais: como treinar redes mais profundas

- Problema: redes muito profundas ficam difíceis de treinar.
- **Aprendizado residual** (HE et al., 2016): o bloco aprende só a diferença $\mathcal{F}(\mathbf{x})$ e soma a entrada:

$$\mathbf{y} = \mathrm{ReLU}\big(\mathcal{F}(\mathbf{x}) + \mathbf{x}\big)$$

- Atalho: identidade, ou projeção 1×1 quando muda a dimensão.
- A cada estágio: comprimento $\div 2$, canais $\times 2$.



Atenção: relacionar instantes distantes do registro

- Convoluções relacionam apenas instantes **vizinhos**; ao final da ResNet-18, o campo receptivo é de cerca de 2,2 s.
- A **autoatenção** (VASWANI et al., 2017) relaciona cada posição com todas as outras em uma única operação:

$$\text{Atenção}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right) V$$

- Neste trabalho: ResNet-18 reduzida como extrator, seguida de **uma camada codificadora** *Transformer* (4 cabeças).
- Custo cresce com o quadrado do comprimento da sequência.

Modelos clássicos: poucas variáveis, poucos eventos

Regressão logística regularizada

L2: reduz os coeficientes sem zerá-los.
L1: zera coeficientes e seleciona variáveis.

Análise de componentes principais

Substitui marcadores correlacionados por poucas combinações não correlacionadas, sem usar o desfecho.

Floresta aleatória (BREIMAN, 2001)

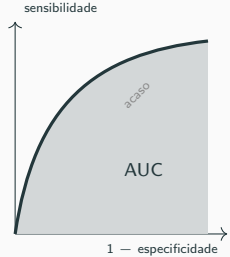
Conjunto de árvores de decisão; captura relações não lineares e interações entre marcadores.

Por que modelos simples?

55 eventos: a regra de dez eventos por variável limita o modelo a poucas variáveis.

Como medir se o modelo separa casos de controles?

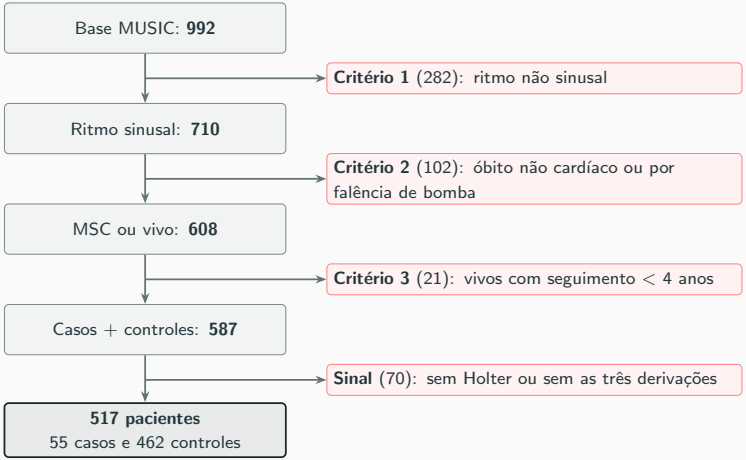
- **AUC**: probabilidade de o modelo dar risco maior a um caso do que a um controle. 0,5 = acaso; 1 = perfeito.
- **AUPRC**: área sob a curva precisão–revocação; acaso = prevalência (0,106) (DAVIS; GOADRICH, 2006).
- **Agregação por paciente**: média das probabilidades das janelas.
- **Intervalo de confiança** por *bootstrap* de pacientes.



A base MUSIC: 992 pacientes acompanhados por quatro anos

- Pública no PhysioNet (MARTIN-YEBRA; MARTÍNEZ; LAGUNA, 2025; MARTÍN-YEBRA et al., 2024).
- **992 pacientes** com insuficiência cardíaca crônica (NYHA II e III), recrutados em 2003–2004 em oito hospitais da Espanha.
- Acompanhamento mediano de 44 meses.
- **Holter de 24 h** em 936 pacientes: derivações X, Y e Z, 200 Hz.
- Causas de óbito **adjudicadas**: separam a MSC da falência de bomba.
- Variáveis clínicas e exames na entrada do estudo.

Quem entra no estudo: de 992 a 517 pacientes



Classificação binária por paciente: MSC (casos) contra sobreviventes em 4 anos (controles). Prevalência de 10,6 %.

O que se sabe do paciente além do Holter

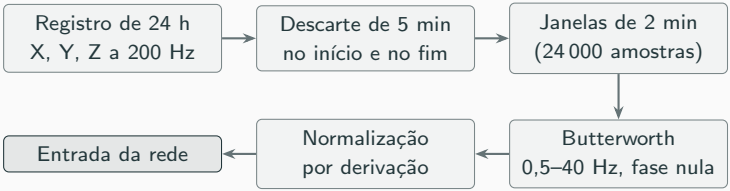
Seis variáveis clínicas

- Idade (anos)
- Classe funcional NYHA (ordinal)
- Gênero
- Ondas Q de necrose
- Taquicardia ventricular não sustentada
- Taquiarritmia supraventricular paroxística

Exames do estudo

- **Ecocardiograma**: FEVE, diâmetros, contratilidade do VD.
- **Laudo do ECG de repouso**: PR, QT, QRS.
- **Medidas do Holter** tabuladas: extrassístoles, SDNN, RMSSD.
- **Pro-BNP**.

Do registro de 24 horas à entrada da rede



- Treinamento: 250 a 350 janelas por paciente, com posição sorteada.
- Avaliação: 100 a 200 janelas em grade regular (reprodutível).
- A escala da normalização é calculada só com o treinamento.

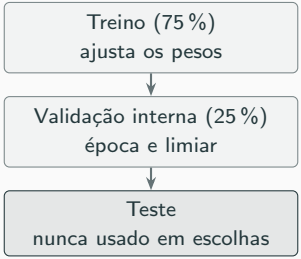
Cenário I: redes de 14 mil a 16 milhões de parâmetros

Família	Variante	Parâmetros	Janela
Convolucional	mínima (3 blocos)	14 425	2 min e 10 s
	simples (4 blocos)	109 361	2 min e 10 s
	média (4 blocos)	418 145	2 min e 10 s
Residual	ResNet-18 mínima	78 169	5,12 s
	ResNet-18 reduzida	1 029 985	2 min
	ResNet-18	3 976 385	2 min e 5,12 s
	ResNet-34	7 350 721	2 min
	ResNet-50	16 479 937	2 min
Atenção	ResNet-18 + *Transformer*	1 491 553	2 min

Capacidade variando em mais de mil vezes: se o desempenho não acompanhar, a limitação está nos dados, e não na rede.

Cenário I: como as redes foram treinadas

- Otimizador **AdamW**, taxa 10^{-4} com decaimento cosseno (LOSHCHILOV; HUTTER, 2017).
- **Desbalanceamento**: perda ponderada, $w_+ \approx 8{,}4$.
- **Seleção da época**: média móvel da AUC de validação nas três últimas épocas.
- **Limiar**: índice de Youden na validação interna.
- **Busca de hiperparâmetros**: Optuna, 25 tentativas por família.

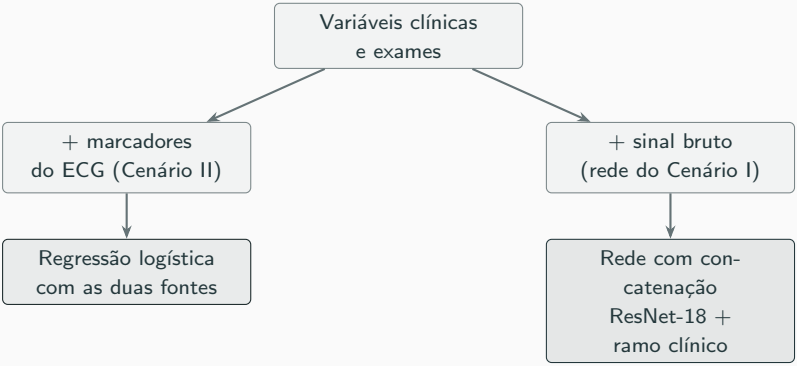


Cenário II: dois protocolos para extrair os marcadores

	Protocolo A	Protocolo B
Segmento	5 minutos	30 segundos
Espaçamento	um por hora	um a cada 2 minutos
Segmentos por paciente	cerca de 21	cerca de 636
Derivação	a de maior desvio-padrão	Y
Domínio da frequência	sim	não
Ectopia	proporção de RR irregulares	contagens completas
Variáveis por paciente	44	32 a 122

- Cada marcador é calculado em cada segmento e **resumido por paciente** (média e desvio-padrão, ou mediana e percentis).
- Modelos: logística L1 e L2, PCA (4) + logística, floresta aleatória.

Cenário III: as variáveis clínicas sozinhas e somadas ao ECG



- Referência: logística L2 sobre as seis variáveis clínicas.
- Rede com concatenação: treino conjunto, taxa reduzida no extrator ou extrator congelado.

Como avaliamos: cada paciente testado uma única vez

- Validação cruzada **estratificada em 5 partições**, dividida por paciente.
- Cada paciente cai no teste **uma única vez**.
- **AUC geral**: uma AUC sobre as predições dos 517 pacientes (medida principal).
- **AUC por partição**: média ± desvio-padrão das cinco AUC de teste.
- Comparações pareadas por *bootstrap*.

Rodada	Teste	Treino
1	104 (11)	413 (44)
2	104 (11)	413 (44)
3	103 (11)	414 (44)
4	103 (11)	414 (44)
5	103 (11)	414 (44)
Total	517 (55)	—

Pacientes (casos).

Cenário I: redes convolucionais não superaram o acaso

Rede	Janela	Parâmetros	AUC por partição	AUC geral [IC 95 %]
Mínima	2 min	14 425	0,543 ± 0,059	0,523 [0,440–0,612]
Simples	2 min	109 361	0,500 ± 0,067	0,486 [0,402–0,578]
Média	2 min	418 145	0,494 ± 0,119	0,485 [0,400–0,574]
Mínima	**10 s**	14 425	0,589 ± 0,090	**0,554** [0,467–0,634]
Simples	10 s	109 361	0,509 ± 0,051	0,491 [0,411–0,578]
Média	10 s	418 145	0,495 ± 0,118	0,485 [0,406–0,569]

Em resumo

Nenhuma configuração se distinguiu do acaso; a rede menor obteve os maiores valores.

Cenário I: redes maiores não ajudaram

Rede	Janela	Parâmetros	AUC por partição	AUC geral [IC 95 %]
ResNet-18 mínima	5,12 s	78 169	0,569 ± 0,067	**0,562** [0,475–0,642]
ResNet-18 reduzida	2 min	1 029 985	0,516 ± 0,102	0,504 [0,420–0,588]
ResNet-18	2 min	3 976 385	0,528 ± 0,088	0,508 [0,431–0,588]
ResNet-34	2 min	7 350 721	0,540 ± 0,039	0,514 [0,429–0,601]
ResNet-50	2 min	16 479 937	0,569 ± 0,098	0,536 [0,448–0,618]

Em resumo

Nem a largura nem a profundidade melhoraram o desempenho.

Cenário I: nem atenção nem busca automática mudaram o quadro

Rede	Janela	Parâmetros	AUC por partição	AUC geral [IC 95 %]
ResNet-18 + atenção	2 min	1 491 553	—	0,493
CNN (Optuna)	1 min	473 417	0,574 ± 0,112	0,556 [0,464–0,647]
ResNet (Optuna)	1 min	1 818 049	0,510 ± 0,079	0,496 [0,411–0,584]

- Relacionar instantes distantes do registro (atenção) não ajudou.
- A busca bayesiana não superou as configurações manuais: a CNN encontrada obteve o mesmo valor da CNN mínima (0,554).

Cenário I: o problema está no sinal, não no procedimento

Variabilidade entre execuções

ResNet-18 mínima treinada duas vezes, nas mesmas partições:

- 0,562 $\rightarrow$ **0,480**

A diferença (0,08) é maior que a diferença entre a melhor e a pior arquitetura.

Sem restrição ao ritmo sinusal

ResNet-18 em 703 pacientes e 85 casos:

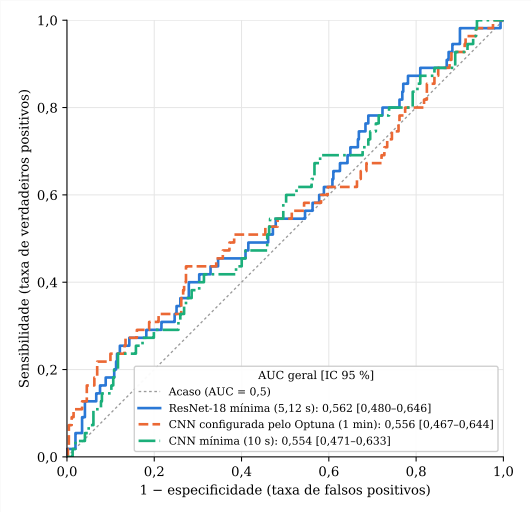
- AUC de **0,575** [0,511–0,642], único intervalo acima de 0,5.

A rede aprende quando há um padrão reconhecível: a fibrilação atrial.

Em resumo

O procedimento funciona; o sinal em ritmo sinusal é que não traz um padrão de MSC reconhecível pelas redes.

Cenário I: curvas próximas da diagonal do acaso



- 15 configurações: AUC geral entre **0,48 e 0,56**.
- Sem relação com a capacidade, a janela ou a atenção.
- Curvas ROC próximas da diagonal do acaso.
- VPP entre 0,09 e 0,14, próximo da prevalência (0,106).

Cenário II: segmentos de 5 minutos superam as redes

Modelo	Variáveis	AUC geral [IC 95 %]	AUPRC
Clínicas (referência)	6	0,661 [0,577–0,741]	0,233
Marcadores, logística L2	44	0,589 [0,507–0,671]	0,180
Marcadores, logística L1	44	0,585 [0,503–0,666]	0,163
Marcadores, PCA (4) + logística	44	**0,624** [0,535–0,708]	0,232
Marcadores, floresta aleatória	44	0,621 [0,537–0,701]	0,184

- Três marcadores resistiram à correção de Benjamini-Hochberg: média e desvio-padrão da potência HF e **desvio-padrão da frequência cardíaca**.
- Escolher poucos marcadores olhando toda a coorte dá cerca de 0,05 a mais (otimismo); dentro da partição, 0,580.

Cenário II: segmentos de 30 s e a armadilha da pseudorreplicação

Unidade de análise

Análise	Signif. (de 24)
Por segmento (328 807)	22
Por paciente (517)	2
Após correção	0

Contar segmentos como pacientes infla a significância (pseudorreplicação (HURLBERT, 1984)).

Modelos

- Treinados **sobre cada segmento**: 0,53 a 0,56.
- Sobre os resumos por paciente (12 configurações): **0,619** [0,537–0,700] no melhor caso (PCA, conjunto 2).
- Padrão consistente: casos com **menor variação da frequência** ao longo do dia.

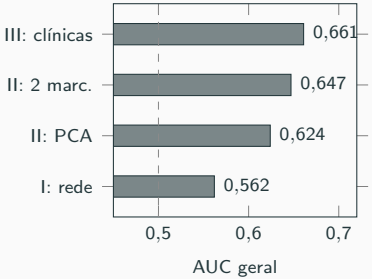
Cenário II: dois marcadores da frequência bastam

Escolhidos de antemão, pela literatura

- desvio-padrão da frequência cardíaca entre os segmentos;
- carga de ectopia;
- sem olhar o desfecho desta coorte.

Modelo e resultado

- logística L2, um modelo por derivação;
- AUC entre 0,635 e 0,660;
- **0,647** [0,563–0,726] na derivação de melhor qualidade.



Em resumo

Dois marcadores ligados à frequência cardíaca: 0,085 acima da melhor rede.

Cenário III: as variáveis clínicas superam todas as redes

Modelo (logística L2)	AUC geral [IC 95 %]
Seis variáveis clínicas	0,661 [0,577–0,741]
Ecocardiograma	0,714 [0,641–0,774]
Clínicas + ecocardiograma	0,720 [0,640–0,789]
Clínicas + todos os exames	**0,733** [0,656–0,804]
Todos os exames	0,738 [0,666–0,809]

- As variáveis clínicas superam todas as redes do Cenário I.
- O ecocardiograma foi o grupo de exames mais informativo (+0,058 sobre as clínicas).
- Pro-BNP: +0,047; laudo do ECG e medidas do Holter acrescentaram pouco.

Cenário III: somar o ECG às clínicas ajuda pouco

Clínicas + marcadores

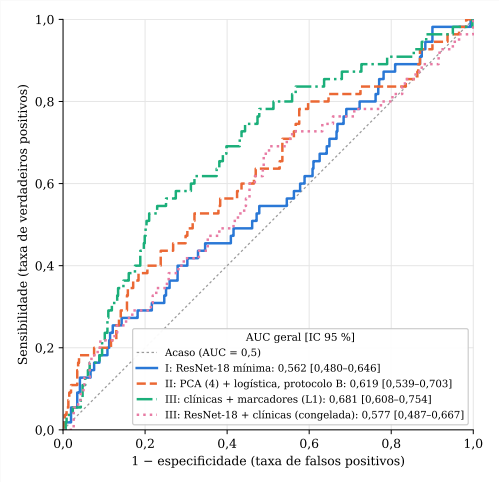
- Protocolo A: 0,661 → **0,681** (L1).
- Dois pré-especificados: 0,679 a 0,683.
- Ganho pequeno e consistente, **sem significância** estatística.

Clínicas + sinal bruto

Estratégia	AUC geral
Treino conjunto	0,516
Taxa reduzida	0,579
Extrator congelado	0,577

Pior que as clínicas sozinhas: o sinal treinado acrescenta variabilidade, não informação.

Os três cenários lado a lado



	Melhores resultados	AUC geral
I	ResNet-18 mínima	0,562
	CNN (Optuna)	0,556
	CNN mínima, 10 s	0,554
II	2 marcadores pré-especificados	0,647
	PCA (4), protocolo A	0,624
	PCA (4), protocolo B	0,619
III	Exames do estudo	0,738
	Clínicas + exames	0,733
	Clínicas + ecocardiograma	0,720

O que aprendemos

- **Cenário I**: redes profundas sobre o sinal bruto ficaram entre 0,48 e 0,56, sem se distinguir do acaso; em ritmo não sinusal, a mesma rede aprende.
- **Cenário II**: os marcadores extraídos do ECG superaram as redes; a informação está em **poucos marcadores** ligados à frequência cardíaca (0,647).
- **Cenário III**: clínicas sozinhas, 0,661; somadas aos marcadores, 0,681; com os exames, até 0,738.

Em resumo

O processamento do ECG com extração de características produziu preditores de MSC superiores ao aprendizado profundo sobre o sinal bruto.

Como esses resultados se comparam à literatura

- **Kim et al.**: 0,60 no subgrupo de insuficiência cardíaca, coerente com as redes deste trabalho.
- **Ramírez et al.**: 0,73 sem validação separada.
- **Swee et al.**: replicação nas condições deles (746 pacientes, derivação Y, segmentos contíguos).

Modelo (só ECG)	AUC por partição
44 marcadores, L1	0,605 $\pm$ 0,088
4 pré-especificados	**0,659** $\pm$ 0,078
Swee et al.	0,682 $\pm$ 0,030

Em resumo

Desempenho próximo ao de Swee et al., com modelos mais simples; a diferença está dentro do intervalo de confiança.

Limitações e próximos passos

Limitações

- Coorte única, sem validação externa.
- Um único Holter por paciente.
- Busca de hiperparâmetros sem validação cruzada aninhada.
- Desfecho binário em 4 anos, sem o tempo até o evento.

Trabalhos futuros

- Modelos sequenciais sobre os marcadores dos segmentos.
- Representações pré-treinadas e orientadas por atributos clínicos.
- Marcadores da repolarização (alternância da onda T).
- Análise de sobrevivência com riscos competitivos.
- Validação externa.

Obrigado!

Perguntas?

Daniel Oliveira dos Santos — MDCC/UFC

Apoio: CAPES — Código de Financiamento 001

Referências i

BARDY, G. H. et al. Amiodarone or an implantable cardioverter-defibrillator for congestive heart failure. *The New England Journal of Medicine*, v. 352, n. 3, p. 225–237, 2005.

BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.

DAVIS, J.; GOADRICH, M. The relationship between precision-recall and ROC curves. In: *Proceedings of the 23rd International Conference on Machine Learning*. [S.l.: s.n.], 2006. p. 233–240.

HANNUN, A. Y. et al. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature Medicine*, v. 25, n. 1, p. 65–69, 2019.

HE, K. et al. Deep residual learning for image recognition. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. [S.l.: s.n.], 2016. p. 770–778.

HURLBERT, S. H. Pseudoreplication and the design of ecological field experiments. *Ecological Monographs*, v. 54, n. 2, p. 187–211, 1984.

KAPOOR, S.; NARAYANAN, A. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, v. 4, n. 9, p. 100804, 2023.

Referências ii

KIM, J. Y. et al. Deep learning-based risk assessment and prediction of cardiac outcomes using single-lead 24-hour Holter-ECG in patients with heart failure or myocardial infarction. *Journal of Clinical Medicine*, v. 14, n. 20, p. 7209, 2025.

LOSHCHILOV, I.; HUTTER, F. SGDR: Stochastic gradient descent with warm restarts. In: *International Conference on Learning Representations (ICLR)*. [S.l.: s.n.], 2017.

MAKOWSKI, D. et al. NeuroKit2: A Python toolbox for neurophysiological signal processing. *Behavior Research Methods*, v. 53, n. 4, p. 1689–1696, 2021.

MARTÍN-YEBRA, A. et al. The MUSIC database: Sudden cardiac death in heart failure patients. In: *Computing in Cardiology*. [S.l.: s.n.], 2024. v. 51.

MARTIN-YEBRA, A.; MARTÍNEZ, J. P.; LAGUNA, P. *MUSIC (Sudden Cardiac Death in Chronic Heart Failure) (version 1.0.1)*. PhysioNet, 2025. RRID:SCR_007345. Disponível em: ⟨https://physionet.org/content/music-sudden-cardiac-death/1.0.1/⟩.

RAMÍREZ, J. et al. Sudden cardiac death and pump failure death prediction in chronic heart failure by combining ECG and clinical markers in an integrated risk model. *PLoS ONE*, v. 12, n. 10, p. e0186152, 2017.

RIBEIRO, A. H. et al. Automatic diagnosis of the 12-lead ECG using a deep neural network. *Nature Communications*, v. 11, p. 1760, 2020.

Referências iii

SWEE, S. et al. Multimodal integration of ambulatory ECG and clinical features for sudden cardiac death and pump failure death prediction. *medRxiv*, 2026. Disponível em: ⟨https://doi.org/10.64898/2026.04.21.26351421⟩.

TOMASELLI, G. F.; ZIPES, D. P. What causes sudden death in heart failure? *Circulation Research*, v. 95, n. 8, p. 754–763, 2004.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2017. v. 30, p. 5998–6008.

ZEPPENFELD, K. et al. 2022 ESC guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death. *European Heart Journal*, v. 43, n. 40, p. 3997–4126, 2022.