Aprendizado de máquina para estratificação de risco de morte súbita cardíaca a partir do Holter de 24 horas

Defesa de dissertação de mestrado



Daniel Oliveira dos Santos

Orientador: Prof. Dr. João Paulo do Vale Madeiro

Coorientador: Prof. José Maria da Silva Monteiro Filho

4 de novembro de 2026

Programa de Pós-Graduação em Ciência da Computação (MDCC)
Universidade Federal do Ceará

Roteiro

1. Introdução
2. Trabalhos relacionados
3. Fundamentação teórica
4. Metodologia
5. Resultados
6. Conclusões

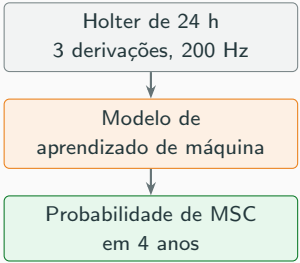
Motivação do problema

- Na insuficiência cardíaca, a morte ocorre por duas vias:
  - **falência de bomba**: deterioração progressiva;
  - **morte súbita cardíaca (MSC)**: evento abrupto, em geral por arritmia ventricular, em paciente muitas vezes estável.
- A MSC responde por cerca de **metade** das mortes nessa população [16].
- Prevenção: o **cardiodesfibrilador implantável**, que reduziu a mortalidade [1].
- A indicação baseia-se na **fração de ejeção (FEVE)**, critério imperfeito [18]:
  - muitos pacientes com o dispositivo nunca o utilizam;
  - parte das mortes súbitas ocorre com FEVE acima do limiar.

Há espaço para ferramentas que estratifiquem melhor o risco de MSC.

Modelos preditivos para a morte súbita cardíaca

- Estimam, para cada paciente, a **probabilidade** do evento em um horizonte definido.
- Permitem ordenar os pacientes por risco, em vez de depender de um único limiar clínico.
- O **Holter de 24 horas** é não invasivo, barato e amplamente disponível.
- Capta ectopias, pausas e variações da frequência entre sono e vigília.



O que a literatura tem feito

Marcadores definidos por especialistas

- VFC, ectopia, turbulência, dinâmica da repolarização.
- Combinados com variáveis clínicas em modelos estatísticos ou de aprendizado de máquina clássico.
- Na base MUSIC: [13, 15].

Redes profundas sobre o sinal

- Sucesso em diagnóstico: arritmias no Holter [4], ECG de 12 derivações [14].
- Na predição de eventos, os melhores resultados usaram redes **pré-treinadas** em grandes bases [8].

Desafios e lacunas

- **Predição $\neq$ diagnóstico**: o evento ocorre meses ou anos depois do Holter, e as coortes têm poucas centenas de pacientes.

1. **Falta de comparação direta**: cada estudo avaliou uma única abordagem, em coortes e protocolos diferentes.
2. **Avaliação otimista**: métricas por trecho do sinal (cada paciente conta centenas de vezes) e seleção de variáveis com o desfecho de toda a coorte [7].
3. **Fibrilação atrial na coorte**: ritmo fácil de reconhecer e de pior prognóstico, que pode inflar a discriminação.

Comparar as abordagens nos mesmos pacientes, com avaliação por paciente e em ritmo sinusal.

Objetivos

Objetivo geral

Investigar métodos de aprendizado de máquina e de pré-processamento do ECG para prever a MSC em pacientes com insuficiência cardíaca crônica, a partir do Holter de 24 horas, em quatro anos de acompanhamento.

Objetivos específicos

(i) Comparar três cenários:

I. aprendizado profundo sobre o sinal bruto;
II. pré-processamento, extração de características e aprendizado de máquina clássico;
III. variáveis clínicas, isoladas e combinadas ao ECG.

(ii) Quantificar o ganho de combinar dados clínicos e do ECG.

(iii) Posicionar os resultados em relação à literatura.

Marcadores do ECG e clínicos na coorte MUSIC

Ramírez et al. (2017) [13]

- 597 pacientes em ritmo sinusal, 49 mortes súbitas.
- Marcadores da repolarização e turbulência + clínicos, em modelo de Cox.
- AUC de 0,73 na FEVE reduzida, **sem validação separada**.

Swee et al. (2026) [15]

- 746 pacientes, **sem restrição de ritmo**, derivação Y.
- Marcadores de segmentos de 30 s; sequência processada por rede convolucional temporal (múltiplas instâncias).
- AUC de 0,682 $\pm$ 0,030 apenas com o ECG (média entre partições).

Aprendizado profundo no Holter e posicionamento

Kim et al. (2025) [8]

- 1 108 pacientes (infarto ou insuficiência cardíaca), 70 eventos.
- Codificador pré-treinado e congelado; só um classificador pequeno é ajustado.
- AUC de 0,74 na coorte completa, mas **0,60** no subgrupo com insuficiência cardíaca.

Este trabalho

- Três abordagens no **mesmo protocolo** e nos mesmos pacientes.
- Controle do otimismo: avaliação por paciente, seleção dentro da partição, intervalos de confiança.
- Restrição ao **ritmo sinusal**.

Pré-processamento do ECG

- **Interferências**: oscilação de linha de base (< 0,5 Hz), ruído muscular, rede elétrica (50 Hz).
- **Filtro passa-faixa** Butterworth 0,5–40 Hz, aplicado nos dois sentidos (fase nula).
- **Normalização** da amplitude por derivação.
- **Janelas**: o registro de 24 h é dividido em trechos; janelas de um mesmo paciente **não são independentes**.



10 s de Holter, derivações X, Y e Z, após o filtro.

Extração de características do ECG

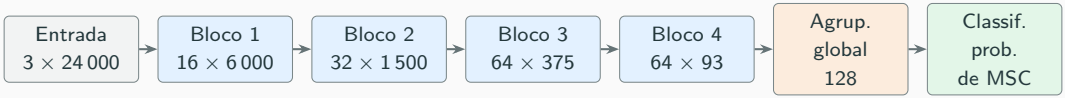
- **Detecção do QRS** e delineação das ondas (NeuroKit2 [10]).
- **Intervalos RR e NN**: NN = entre batimentos normais.
- **VFC**: SDNN, RMSSD, pNN50, potências LF e HF, Poincaré (SD1, SD2), entropia amostral.
- **Morfologia**: QRS, QT, QTc, ondas P e T.
- **Ectopia**: extrassístoles, dupletes, pausas.

Medida	5 min	30 s
Domínio do tempo	sim	sim
LF, HF, LF/HF	sim	não
Entropia amostral	sim	não
Morfologia	sim	sim
Contagens de ectopia	sim	sim

A duração do segmento limita quais medidas são confiáveis.

Redes convolucionais unidimensionais

- **Convolução 1D**: filtros que deslizam no tempo e detectam padrões locais (núcleo de 75 ms $\approx$ um QRS).
- Cada bloco: convolução $\rightarrow$ normalização em lote $\rightarrow$ ReLU $\rightarrow$ agrupamento máximo $\rightarrow$ descarte.
- **Agrupamento global** (média e máximo) e classificador.
- Perda: entropia cruzada ponderada, $w_{+} = N_0/N_1 \approx 8{,}4$.

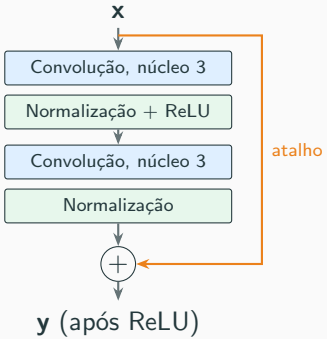


Redes residuais

- Problema: redes muito profundas ficam difíceis de treinar.
- **Aprendizado residual** [5]: o bloco aprende só a diferença $\mathcal{F}(\mathbf{x})$ e soma a entrada:

$$\mathbf{y} = \mathrm{ReLU}\big(\mathcal{F}(\mathbf{x}) + \mathbf{x}\big)$$

- Atalho: identidade, ou projeção 1×1 quando muda a dimensão.
- A cada estágio: comprimento $\div 2$, canais $\times 2$.



Mecanismo de atenção

- Convoluções relacionam apenas instantes **vizinhos**; ao final da ResNet-18, o campo receptivo é de cerca de 2,2 s.
- A **autoatenção** [17] relaciona cada posição com todas as outras em uma única operação:

$$\text{Atenção}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^{\top}}{\sqrt{d}}\right) V$$

- Neste trabalho: ResNet-18 reduzida como extrator, seguida de **uma camada codificadora** *Transformer* (4 cabeças).
- Custo cresce com o quadrado do comprimento da sequência.

Modelos de aprendizado de máquina clássico

Regressão logística regularizada
L2: reduz os coeficientes sem zerá-los.

L1: zera coeficientes e seleciona variáveis.

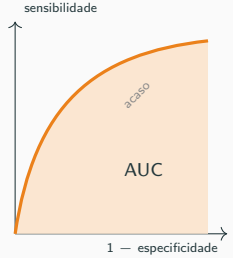
Análise de componentes principais
Substitui marcadores correlacionados por poucas combinações não correlacionadas, sem usar o desfecho.

Floresta aleatória [2]
Conjunto de árvores de decisão; captura relações não lineares e interações entre marcadores.

Por que modelos simples?
55 eventos: a regra de dez eventos por variável limita o modelo a poucas variáveis.

Avaliação de classificadores

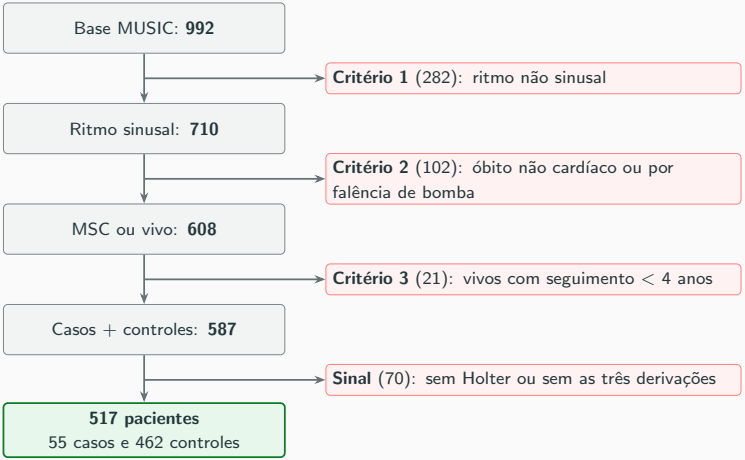
- **AUC**: probabilidade de o modelo dar risco maior a um caso do que a um controle. 0,5 = acaso; 1 = perfeito.
- **AUPRC**: área sob a curva precisão–revocação; acaso = prevalência (0,106) [3].
- **Agregação por paciente**: média das probabilidades das janelas.
- **Intervalo de confiança** por *bootstrap* de pacientes.



Base de dados MUSIC

- Pública no PhysioNet [11, 12].
- **992 pacientes** com insuficiência cardíaca crônica (NYHA II e III), recrutados em 2003–2004 em oito hospitais da Espanha.
- Acompanhamento mediano de 44 meses.
- **Holter de 24 h** em 936 pacientes: derivações X, Y e Z, 200 Hz.
- Causas de óbito **adjudicadas**: separam a MSC da falência de bomba.
- Variáveis clínicas e exames na entrada do estudo.

População de estudo e critérios de seleção



Classificação binária por paciente: MSC (casos) contra sobreviventes em 4 anos (controles). Prevalência de 10,6 %.

Variáveis clínicas e exames

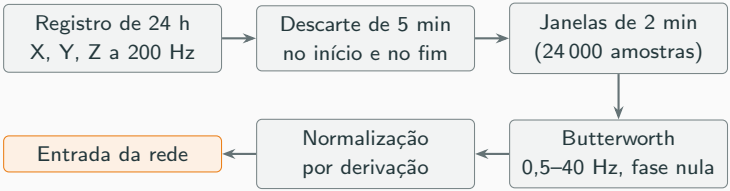
Seis variáveis clínicas

- Idade (anos)
- Classe funcional NYHA (ordinal)
- Gênero
- Ondas Q de necrose
- Taquicardia ventricular não sustentada
- Taquiarritmia supraventricular paroxística

Exames do estudo

- **Ecocardiograma**: FEVE, diâmetros, contratilidade do VD.
- **Laudo do ECG de repouso**: PR, QT, QRS.
- **Medidas do Holter** tabuladas: extrassístoles, SDNN, RMSSD.
- **Pro-BNP**.

Pré-processamento do sinal



- Treinamento: 250 a 350 janelas por paciente, com posição sorteada.
- Avaliação: 100 a 200 janelas em grade regular (reprodutível).
- A escala da normalização é calculada só com o treinamento.

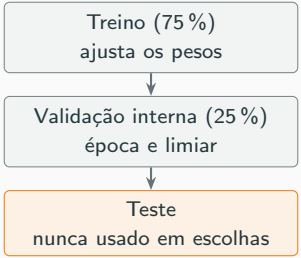
Cenário I: arquiteturas avaliadas

Família	Variante	Parâmetros	Janela
Convolucional	mínima (3 blocos)	14 425	2 min e 10 s
	simples (4 blocos)	109 361	2 min e 10 s
	média (4 blocos)	418 145	2 min e 10 s
Residual	ResNet-18 mínima	78 169	5,12 s
	ResNet-18 reduzida	1 029 985	2 min
	ResNet-18	3 976 385	2 min e 5,12 s
	ResNet-34	7 350 721	2 min
	ResNet-50	16 479 937	2 min
Atenção	ResNet-18 + *Transformer*	1 491 553	2 min

Capacidade variando em mais de mil vezes: se o desempenho não acompanhar, a limitação está nos dados, e não na rede.

Cenário I: treinamento das redes

- Otimizador **AdamW**, taxa 10^{-4} com decaimento cosseno [9].
- **Desbalanceamento**: perda ponderada, $w_+ \approx 8{,}4$.
- **Seleção da época**: média móvel da AUC de validação nas três últimas épocas.
- **Limiar**: índice de Youden na validação interna.
- **Busca de hiperparâmetros**: Optuna, 25 tentativas por família.

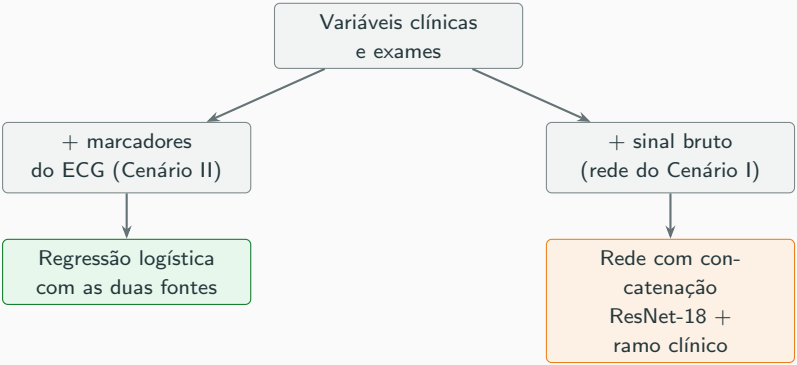


Cenário II: protocolos de extração dos marcadores

	Protocolo A	Protocolo B
Segmento	5 minutos	30 segundos
Espaçamento	um por hora	um a cada 2 minutos
Segmentos por paciente	cerca de 21	cerca de 636
Derivação	a de maior desvio-padrão	Y
Domínio da frequência	sim	não
Ectopia	proporção de RR irregulares	contagens completas
Variáveis por paciente	44	32 a 122

- Cada marcador é calculado em cada segmento e **resumido por paciente** (média e desvio-padrão, ou mediana e percentis).
- Modelos: logística L1 e L2, PCA (4) + logística, floresta aleatória.

Cenário III: variáveis clínicas e combinação com o ECG



- Referência: logística L2 sobre as seis variáveis clínicas.
- Rede com concatenação: treino conjunto, taxa reduzida no extrator ou extrator congelado.

Protocolo de avaliação

- Validação cruzada **estratificada em 5 partições**, dividida por paciente.
- Cada paciente cai no teste **uma única vez**.
- **AUC geral**: uma AUC sobre as predições dos 517 pacientes (medida principal).
- **AUC por partição**: média $\pm$ desvio-padrão das cinco AUC de teste.
- Comparações pareadas por *bootstrap*.

Rodada	Teste	Treino
1	104 (11)	413 (44)
2	104 (11)	413 (44)
3	103 (11)	414 (44)
4	103 (11)	414 (44)
5	103 (11)	414 (44)
Total	517 (55)	—

Pacientes (casos).

Cenário I: redes convolucionais

Rede	Janela	Parâmetros	AUC por partição	AUC geral [IC 95 %]
Mínima	2 min	14 425	0,543 ± 0,059	0,523 [0,440–0,612]
Simples	2 min	109 361	0,500 ± 0,067	0,486 [0,402–0,578]
Média	2 min	418 145	0,494 ± 0,119	0,485 [0,400–0,574]
Mínima	**10 s**	14 425	0,589 ± 0,090	**0,554** [0,467–0,634]
Simples	10 s	109 361	0,509 ± 0,051	0,491 [0,411–0,578]
Média	10 s	418 145	0,495 ± 0,118	0,485 [0,406–0,569]

Nenhuma configuração se distinguiu do acaso; a rede menor obteve os maiores valores.

Cenário I: redes residuais

Rede	Janela	Parâmetros	AUC por partição	AUC geral [IC 95 %]
ResNet-18 mínima	5,12 s	78 169	0,569 ± 0,067	**0,562** [0,475–0,642]
ResNet-18 reduzida	2 min	1 029 985	0,516 ± 0,102	0,504 [0,420–0,588]
ResNet-18	2 min	3 976 385	0,528 ± 0,088	0,508 [0,431–0,588]
ResNet-34	2 min	7 350 721	0,540 ± 0,039	0,514 [0,429–0,601]
ResNet-50	2 min	16 479 937	0,569 ± 0,098	0,536 [0,448–0,618]

Nem a largura nem a profundidade melhoraram o desempenho.

Cenário I: atenção e busca de hiperparâmetros

Rede	Janela	Parâmetros	AUC por partição	AUC geral [IC 95 %]
ResNet-18 + atenção	2 min	1 491 553	—	0,493
CNN (Optuna)	1 min	473 417	0,574 ± 0,112	0,556 [0,464–0,647]
ResNet (Optuna)	1 min	1 818 049	0,510 ± 0,079	0,496 [0,411–0,584]

- Relacionar instantes distantes do registro (atenção) não ajudou.
- A busca bayesiana não superou as configurações manuais: a CNN encontrada obteve o mesmo valor da CNN mínima (0,554).

Cenário I: variabilidade e análise de sensibilidade

Variabilidade entre execuções
ResNet-18 mínima treinada duas vezes, nas mesmas partições:

- 0,562 → **0,480**

A diferença (0,08) é maior que a diferença entre a melhor e a pior arquitetura.

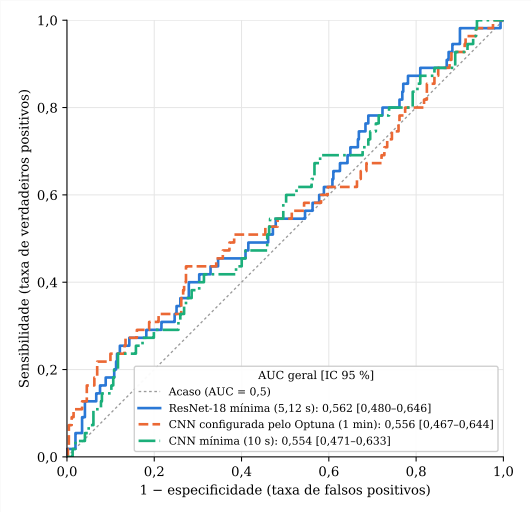
Sem restrição ao ritmo sinusal
ResNet-18 em 703 pacientes e 85 casos:

- AUC de **0,575** [0,511–0,642], único intervalo acima de 0,5.

A rede aprende quando há um padrão reconhecível: a fibrilação atrial.

O procedimento funciona; o sinal em ritmo sinusal é que não traz um padrão de MSC reconhecível pelas redes.

Cenário I: síntese



- 15 configurações: AUC geral entre **0,48 e 0,56**.
- Sem relação com a capacidade, a janela ou a atenção.
- Curvas ROC próximas da diagonal do acaso.
- VPP entre 0,09 e 0,14, próximo da prevalência (0,106).

Cenário II: protocolo A (segmentos de 5 min)

Modelo	Variáveis	AUC geral [IC 95 %]	AUPRC
Clínicas (referência)	6	0,661 [0,577–0,741]	0,233
Marcadores, logística L2	44	0,589 [0,507–0,671]	0,180
Marcadores, logística L1	44	0,585 [0,503–0,666]	0,163
Marcadores, PCA (4) + logística	44	**0,624** [0,535–0,708]	0,232
Marcadores, floresta aleatória	44	0,621 [0,537–0,701]	0,184

- Três marcadores resistiram à correção de Benjamini-Hochberg: média e desvio-padrão da potência HF e **desvio-padrão da frequência cardíaca**.
- Escolher poucos marcadores olhando toda a coorte dá cerca de 0,05 a mais (otimismo); dentro da partição, 0,580.

Cenário II: protocolo B (segmentos de 30 s)

Unidade de análise

Análise	Signif. (de 24)
Por segmento (328 807)	22
Por paciente (517)	2
Após correção	0

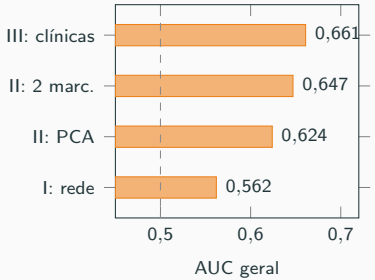
Contar segmentos como pacientes infla a significância (pseudorreplicação [6]).

Modelos

- Treinados **sobre cada segmento**: 0,53 a 0,56.
- Sobre os resumos por paciente (12 configurações): **0,619** [0,537–0,700] no melhor caso (PCA, conjunto 2).
- Padrão consistente: casos com **menor variação da frequência** ao longo do dia.

Cenário II: marcadores pré-especificados

- Escolhidos **de antemão**, pela literatura, sem olhar o desfecho:
  - desvio-padrão da frequência cardíaca entre os segmentos;
  - carga de ectopia.
- Logística L2, um modelo por derivação.
- AUC entre 0,635 e 0,660; **0,647** [0,563–0,726] na derivação de melhor qualidade.



Dois marcadores ligados à frequência cardíaca: 0,085 acima da melhor rede.

Cenário III: variáveis clínicas e exames

Modelo (logística L2)	AUC geral [IC 95 %]
Seis variáveis clínicas	0,661 [0,577–0,741]
Ecocardiograma	0,714 [0,641–0,774]
Clínicas + ecocardiograma	0,720 [0,640–0,789]
Clínicas + todos os exames	**0,733** [0,656–0,804]
Todos os exames	0,738 [0,666–0,809]

- As variáveis clínicas superam todas as redes do Cenário I.
- O ecocardiograma foi o grupo de exames mais informativo (+0,058 sobre as clínicas).
- Pro-BNP: +0,047; laudo do ECG e medidas do Holter acrescentaram pouco.

Cenário III: combinação com o ECG

Clínicas + marcadores

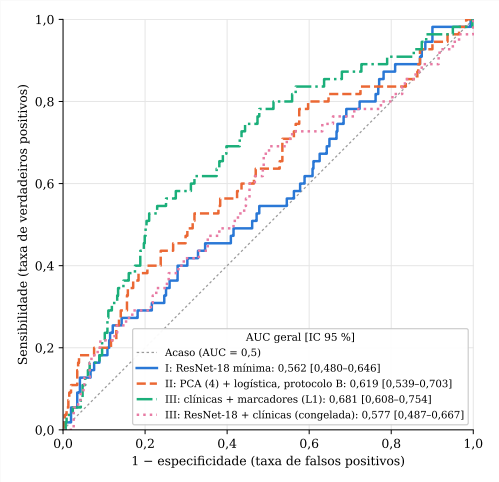
- Protocolo A: 0,661 → **0,681** (L1).
- Dois pré-especificados: 0,679 a 0,683.
- Ganho pequeno e consistente, **sem significância** estatística.

Clínicas + sinal bruto

Estratégia	AUC geral
Treino conjunto	0,516
Taxa reduzida	0,579
Extrator congelado	0,577

Pior que as clínicas sozinhas: o sinal treinado acrescenta variabilidade, não informação.

Síntese dos três cenários



	Melhores resultados	AUC geral
I	ResNet-18 mínima	0,562
	CNN (Optuna)	0,556
	CNN mínima, 10 s	0,554
II	2 marcadores pré-especificados	0,647
	PCA (4), protocolo A	0,624
	PCA (4), protocolo B	0,619
III	Exames do estudo	0,738
	Clínicas + exames	0,733
	Clínicas + ecocardiograma	0,720

Conclusões

- **Cenário I**: redes profundas sobre o sinal bruto ficaram entre 0,48 e 0,56, sem se distinguir do acaso; em ritmo não sinusal, a mesma rede aprende.
- **Cenário II**: os marcadores extraídos do ECG superaram as redes; a informação está em **poucos marcadores** ligados à frequência cardíaca (0,647).
- **Cenário III**: clínicas sozinhas, 0,661; somadas aos marcadores, 0,681; com os exames, até 0,738.

O processamento do ECG com extração de características produziu preditores de MSC superiores ao aprendizado profundo sobre o sinal bruto.

Comparação com os trabalhos relacionados

- **Kim et al.**: 0,60 no subgrupo de insuficiência cardíaca, coerente com as redes deste trabalho.
- **Ramírez et al.**: 0,73 sem validação separada.
- **Swee et al.**: replicação nas condições deles (746 pacientes, derivação Y, segmentos contíguos).

Modelo (só ECG)	AUC por partição
44 marcadores, L1	0,605 $\pm$ 0,088
4 pré-especificados	**0,659** $\pm$ 0,078
Swee et al.	0,682 $\pm$ 0,030

Desempenho próximo ao de Swee et al., com modelos mais simples; a diferença está dentro do intervalo de confiança.

Limitações e trabalhos futuros

Limitações

- Coorte única, sem validação externa.
- Um único Holter por paciente.
- Busca de hiperparâmetros sem validação cruzada aninhada.
- Desfecho binário em 4 anos, sem o tempo até o evento.

Trabalhos futuros

- Modelos sequenciais sobre os marcadores dos segmentos.
- Representações pré-treinadas e orientadas por atributos clínicos.
- Marcadores da repolarização (alternância da onda T).
- Análise de sobrevivência com riscos competitivos.
- Validação externa.

Obrigado!

Perguntas?

Daniel Oliveira dos Santos — MDCC/UFC

Apoio: CAPES — Código de Financiamento 001

Referências i

[1] *Bardy Gust H., Lee Kerry L., Mark Daniel B., others* . Amiodarone or an implantable cardioverter-defibrillator for congestive heart failure // The New England Journal of Medicine. 2005. 352, 3. 225–237.

[2] *Breiman Leo*. Random forests // Machine Learning. 2001. 45, 1. 5–32.

[3] *Davis Jesse, Goadrich Mark*. The relationship between precision-recall and ROC curves // Proceedings of the 23rd International Conference on Machine Learning. 2006. 233–240.

[4] *Hannun Awni Y., Rajpurkar Pranav, Haghpanahi Masoumeh, Tison Geoffrey H., Bourn Codie, Turakhia Mintu P., Ng Andrew Y.* Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network // Nature Medicine. 2019. 25, 1. 65–69.

[5] *He Kaiming, Zhang Xiangyu, Ren Shaoqing, Sun Jian*. Deep residual learning for image recognition // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016. 770–778.

[6] *Hurlbert Stuart H.* Pseudoreplication and the design of ecological field experiments // Ecological Monographs. 1984. 54, 2. 187–211.

[7] *Kapoor Sayash, Narayanan Arvind*. Leakage and the reproducibility crisis in machine-learning-based science // Patterns. 2023. 4, 9. 100804.

Referências ii

[8] *Kim Ju Youn, Kim Kyung Geun, Joo Sunghoon, Chang Mineok, Kim Juwon, Park Kyoung-Min, On Young Keun, Kim June Soo, Lee Young Soo, Park Seung-Jung*. Deep Learning-Based Risk Assessment and Prediction of Cardiac Outcomes Using Single-Lead 24-Hour Holter-ECG in Patients with Heart Failure or Myocardial Infarction // Journal of Clinical Medicine. 2025. 14, 20. 7209.

[9] *Loshchilov Ilya, Hutter Frank*. SGDR: Stochastic Gradient Descent with Warm Restarts // International Conference on Learning Representations (ICLR). 2017.

[10] *Makowski Dominique, Pham Tam, Lau Zen J., Brammer Jan C., Lespinasse François, Pham Hung, Schölzel Christopher, Chen S. H. Annabel*. NeuroKit2: A Python toolbox for neurophysiological signal processing // Behavior Research Methods. 2021. 53, 4. 1689–1696.

[11] *Martín-Yebra Alba, Luna Antoni Bayés de, Vázquez Rafael, Caminal Pere, Laguna Pablo, Martínez Juan Pablo*. The MUSIC Database: Sudden Cardiac Death in Heart Failure Patients // Computing in Cardiology. 51. 2024.

[12] *Martin-Yebra Alba, Martínez Juan Pablo, Laguna Pablo*. MUSIC (Sudden Cardiac Death in Chronic Heart Failure) (version 1.0.1). 2025. RRID:SCR_007345.

Referências iii

[13] *Ramírez Julia, Orini Michele, Mincholé Ana, Monasterio Violeta, Cygankiewicz Iwona, Luna Antoni Bayés de, Martínez Juan Pablo, Laguna Pablo, Pueyo Esther*. Sudden cardiac death and pump failure death prediction in chronic heart failure by combining ECG and clinical markers in an integrated risk model // PLoS ONE. 2017. 12, 10. e0186152.

[14] *Ribeiro Antônio H., Ribeiro Manoel Horta, Paixão Gabriela M. M., Oliveira Derick M., Gomes Paulo R., Canazart Jéssica A., Ferreira Milton P. S., Andersson Carl R., Macfarlane Peter W., Meira Jr. Wagner, Schön Thomas B., Ribeiro Antonio Luiz P.* Automatic diagnosis of the 12-lead ECG using a deep neural network // Nature Communications. 2020. 11. 1760.

[15] *Swee Steven, Adam Irsyad, Zheng Erika Yilin, Ji Ethan, Wang Ding, Speier William, Hsu Jeffrey, Chang Kai-Wei, Shivkumar Kalyanam, Ping Peipei*. Multimodal Integration of Ambulatory ECG and Clinical Features for Sudden Cardiac Death and Pump Failure Death Prediction // medRxiv. 2026.

[16] *Tomaselli Gordon F., Zipes Douglas P.* What causes sudden death in heart failure? // Circulation Research. 2004. 95, 8. 754–763.

[17] *Vaswani Ashish, Shazeer Noam, Parmar Niki, Uszkoreit Jakob, Jones Llion, Gomez Aidan N., Kaiser Łukasz, Polosukhin Illia*. Attention is all you need // Advances in Neural Information Processing Systems. 30. 2017. 5998–6008.

Referências iv

[18] *Zeppenfeld Katja, Tfelt-Hansen Jacob, Riva Marta de, others* . 2022 ESC Guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death // European Heart Journal. 2022. 43, 40. 3997–4126.