Aprendizado de máquina para estratificação de risco de morte súbita cardíaca a partir do Holter de 24 horas

Apresentação da proposta de dissertação

Daniel Oliveira dos Santos

Orientador: Prof. Dr. João Paulo do Vale Madeiro

Coorientador: Prof. José Maria da Silva Monteiro Filho

26 de outubro de 2026

Programa de Pós-Graduação em Ciência da Computação (MDCC)
Universidade Federal do Ceará

Sumário

1. Introdução

2. Fundamentação teórica

3. Trabalhos relacionados

4. Metodologia

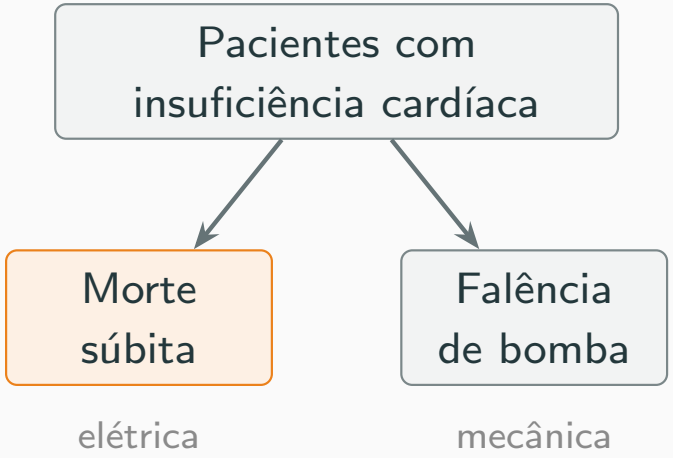
5. Resultados preliminares

6. Próximos passos

Introdução

Morte súbita cardíaca: o problema

- Morte de causa cardíaca, inesperada e rápida, em geral por arritmia ventricular
- Na insuficiência cardíaca, disputa espaço com a morte por **falência de bomba**, de mecanismo mecânico e progressivo
- Prevenir exige saber **quem** está em risco **elétrico**, e não apenas quem está mais grave
- O evento é raro mesmo nessa população: poucos casos para aprender



Por que o Holter de 24 horas?

- Exame barato, não invasivo e de rotina
- Observa o coração ao longo do dia, e não em poucos segundos
- Capta ectopias, pausas e a variação da frequência entre sono e vigília
- Três derivações ortogonais (X, Y e Z), 200 Hz: cerca de 17 milhões de amostras por paciente



Trecho de 10 s de um paciente da coorte

Objetivos e perguntas de pesquisa

Objetivo geral: investigar se o Holter de 24 h contém informação para identificar, entre pacientes com insuficiência cardíaca, os que viriam a sofrer morte súbita.

Perguntas de pesquisa

1. Redes profundas treinadas diretamente sobre o sinal superam os marcadores clássicos do ECG?
2. Aprender representações do sinal (com rótulos substitutos ou sem rótulos) ajuda quando há poucos eventos?
3. O Holter acrescenta informação às variáveis clínicas e aos exames já medidos?

Restrição central: 517 pacientes e apenas 55 eventos.

Fundamentação teórica

Biomarcadores do Holter

Medidas definidas por especialistas, extraídas com o NeuroKit2 [7] em segmentos de 30 s:

Variabilidade
SDNN, RMSSD, pNN50
Potência LF e HF
Poincaré (SD1, SD2)
Entropia amostral

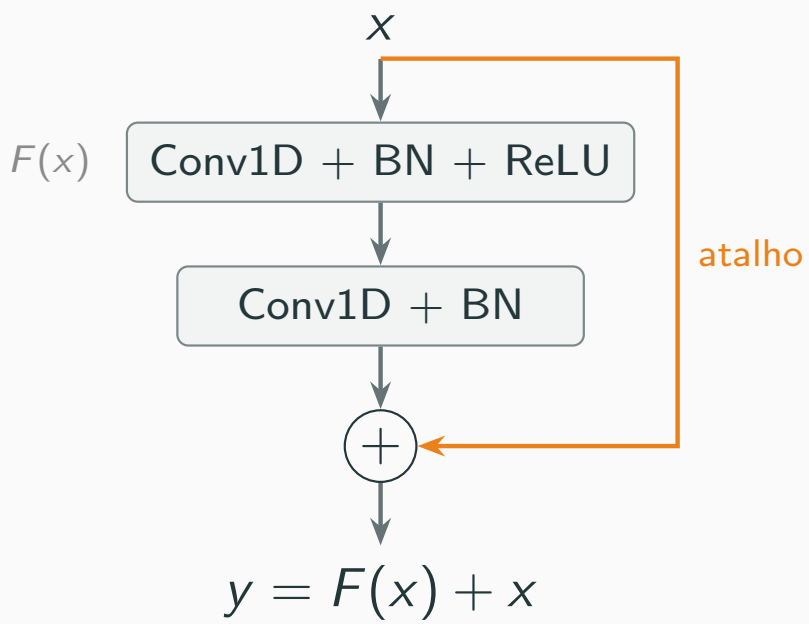
Ectopia e ritmo
Carga de ectopia
Dupletes
Maior pausa
Frequência cardíaca média

Morfologia
Duração do QRS
Intervalos QT e QTc
Ondas P e T
Amplitude por derivação

Cada marcador é resumido por paciente (média e desvio-padrão ao longo do registro) e usado em uma regressão logística.

Redes convolucionais 1D e a ResNet

- Filtros deslizam ao longo do tempo e aprendem padrões locais do sinal [6]
- Camadas empilhadas combinam padrões em escalas maiores
- A **ResNet** soma a entrada à saída de cada bloco, o que permite treinar redes profundas [3]
- Bem-sucedidas no ECG quando há **muitos** exemplos rotulados



Aprendizado multitarefa e autossupervisionado

Multitarefa [1]

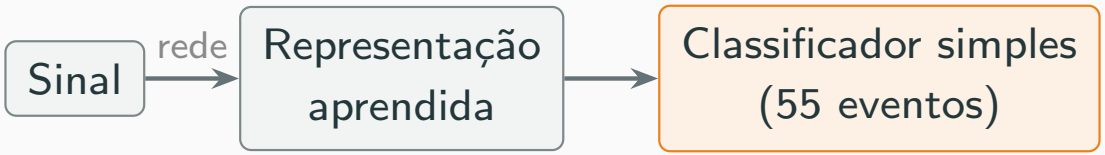
A rede aprende várias tarefas ao mesmo tempo e compartilha a representação entre elas.

Aqui: prever **atributos clínicos** disponíveis para quase todos os pacientes (QRS, FEVE, ondas Q, Pro-BNP. . .) como **rótulos substitutos**.

Autossupervisionado [2]

A rede aprende sem rótulos, a partir do próprio sinal.

Contrastivo: janelas do mesmo paciente devem ter representações próximas; de pacientes diferentes, distantes.



Ideia comum: a rede aprende com muitos rótulos ou sem rótulos; o desfecho raro entra só no fim.

Trabalhos relacionados

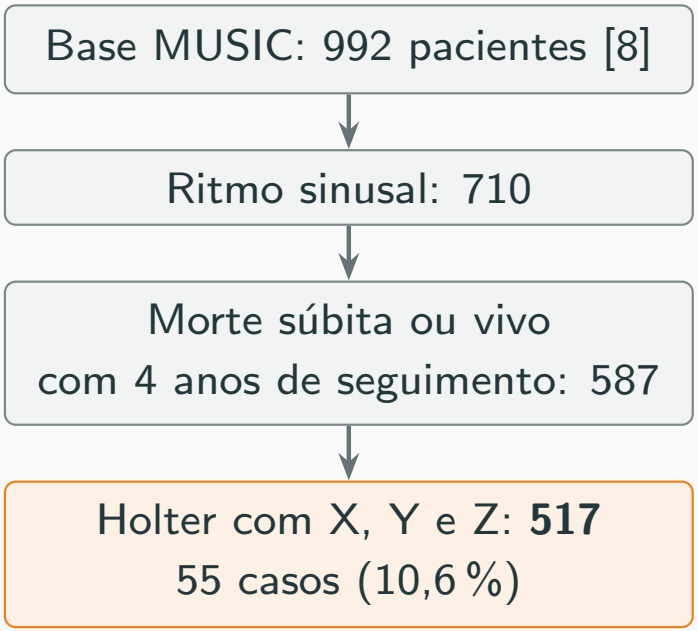
Estudos com a coorte MUSIC e com o Holter

Trabalho	Coorte	Método	Resultado
Ramírez et al. [10]	MUSIC, ritmo sinusal; 597 pacientes, 49 mortes súbitas	Marcadores de repolarização + clínicos; Cox	AUC 0,73 na FEVE reduzida (sem validação separada)
Swee et al. [11]	MUSIC, todos os ritmos; 746 pacientes	Marcadores de segmentos de 30 s (derivação Y) + aprendizado de máquina	AUC 0,682 $\pm$ 0,030 só com o ECG
Kim et al. [5]	Coreia; 1 108 pacientes, 70 eventos	Codificador pré-treinado + FEVE como rótulo substituto	AUC 0,74; **0,60** na insuficiência cardíaca

Lacuna: comparar, na mesma coorte e no mesmo protocolo, marcadores, redes treinadas no desfecho e representações aprendidas.

Metodologia

A coorte MUSIC e o pré-processamento

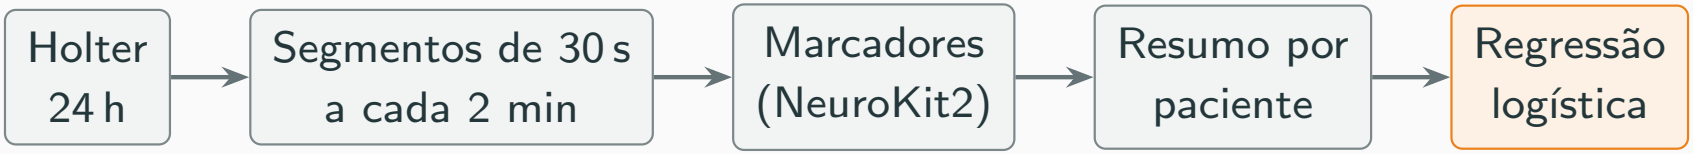


Pré-processamento

- Filtro passa-faixa de 0,5 a 40 Hz
- Descarte da 1.ª e da última hora
- Janelas de 30 s espalhadas pelo registro
- Correção dos intervalos RR e controle de qualidade por derivação

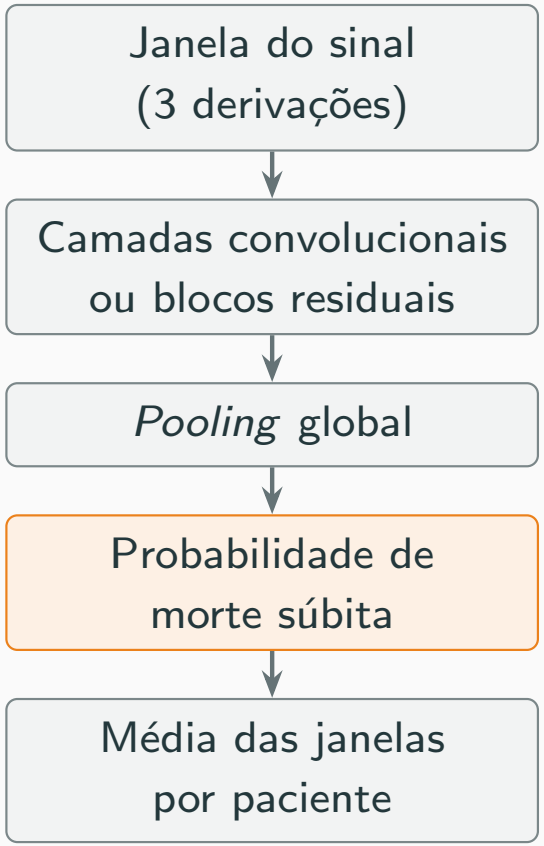
Dados públicos no PhysioNet [9].

Abordagem 1: biomarcadores e regressão logística



- Segmentos com menos de 80 % de batimentos normais são descartados
- Por segmento, usa-se a derivação mais limpa
- **Modelo pré-especificado**: dois marcadores escolhidos pela literatura, e não pelos dados
  - variação da frequência cardíaca ao longo do dia
  - carga de ectopia
- Dois protocolos de extração: **A**, segmentos de 5 min com 44 marcadores; **B**, segmentos de 30 s
- Escolher os marcadores olhando o desfecho de toda a coorte superestima o desempenho [4]

Abordagem 2: redes treinadas direto no desfecho

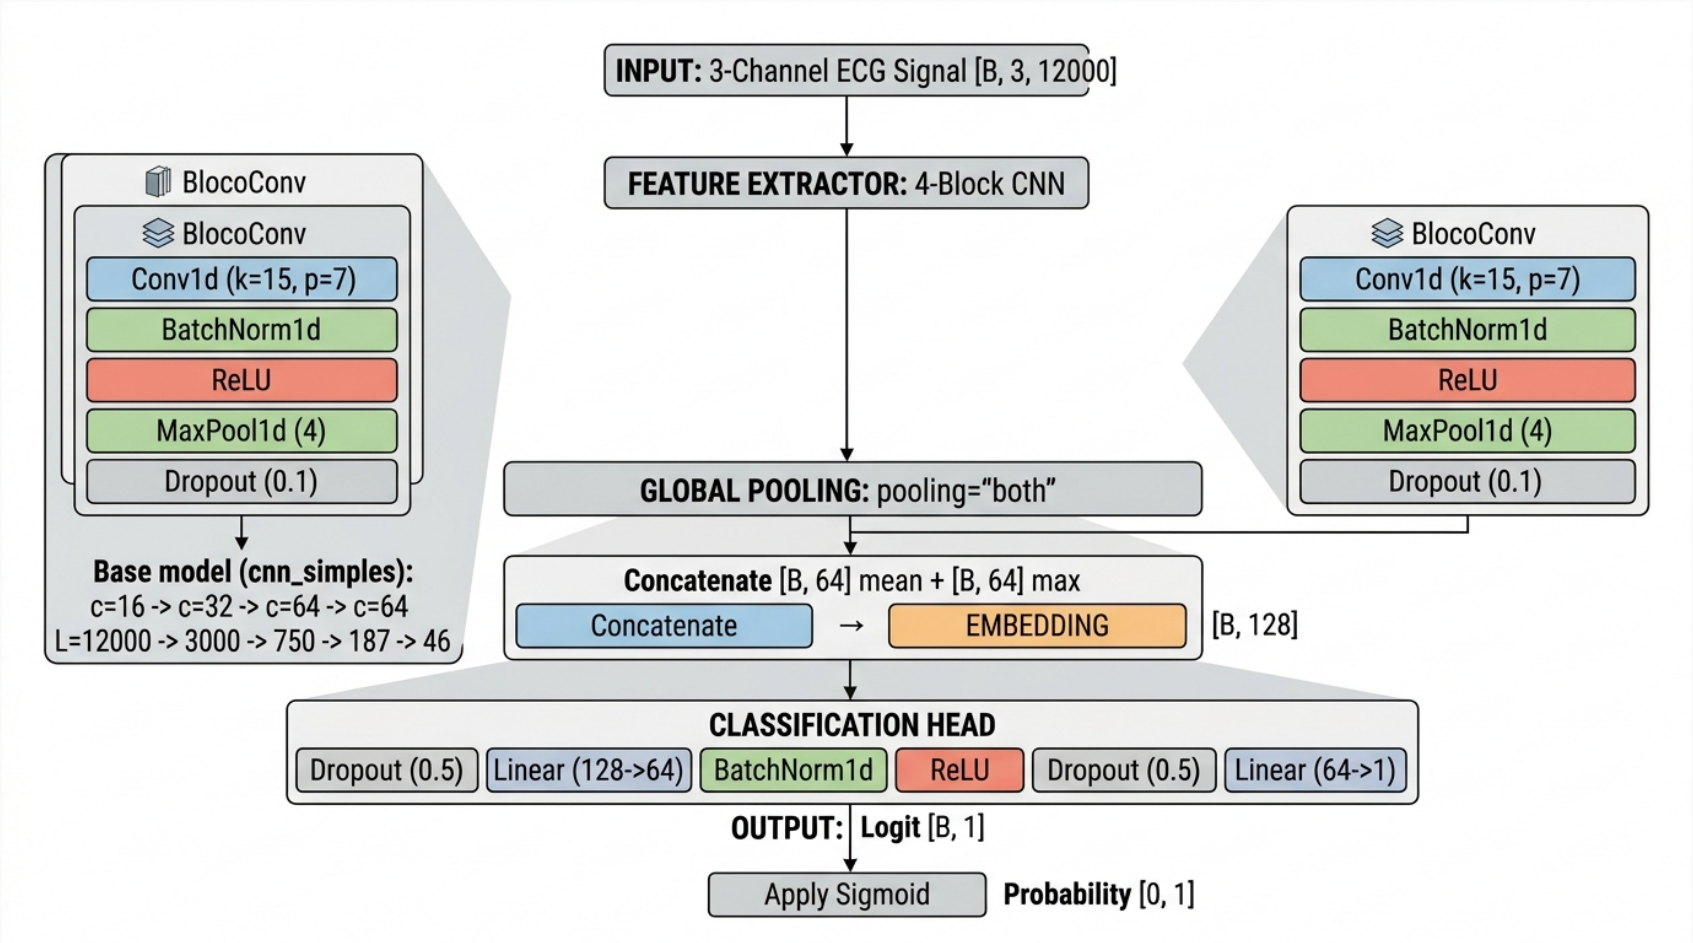


Configurações avaliadas (19)

- CNNs de três capacidades (14 mil a 418 mil parâmetros)
- ResNet-18, ResNet-34 e ResNet-50
- ResNet-18 + *Transformer*
- Fusão com as variáveis clínicas
- Janelas de 5 s a 2 min
- Busca de hiperparâmetros

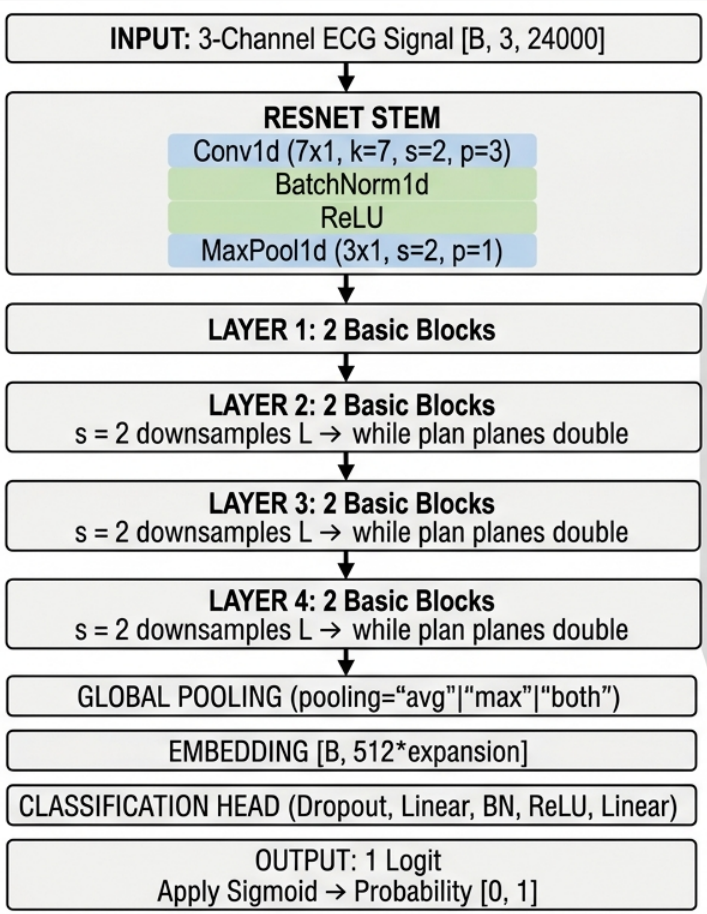
O único rótulo é o desfecho: 33 casos de treino por partição.

Arquitetura da CNN



Quatro blocos convolucionais, *pooling* global (média e máximo) e cabeça de classificação. A capacidade varia com o número de canais.

Arquitetura da ResNet-18



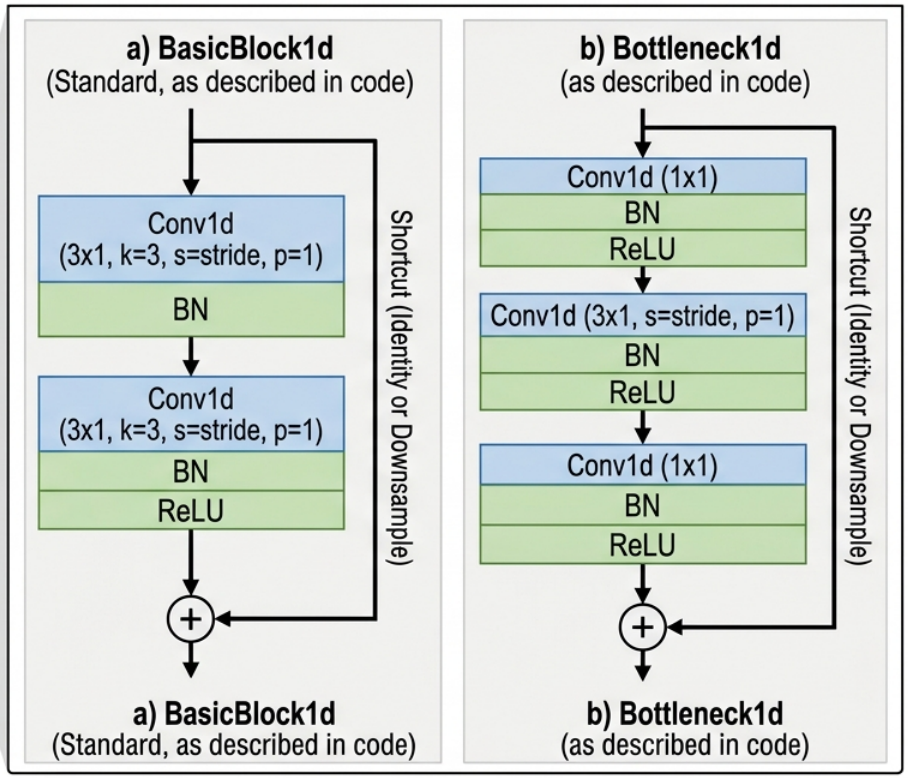
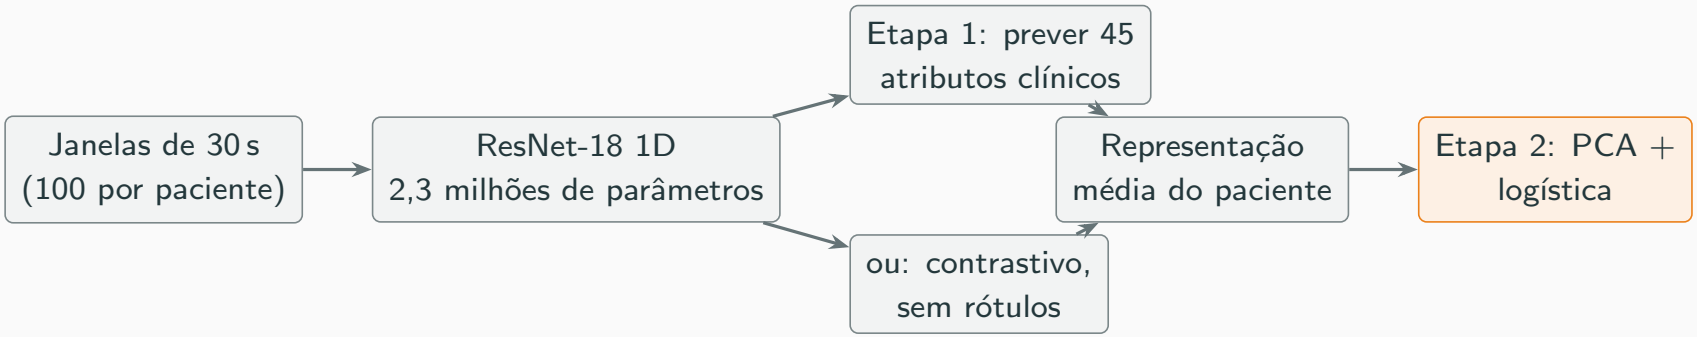


Figure 2: ResNet Block Variants

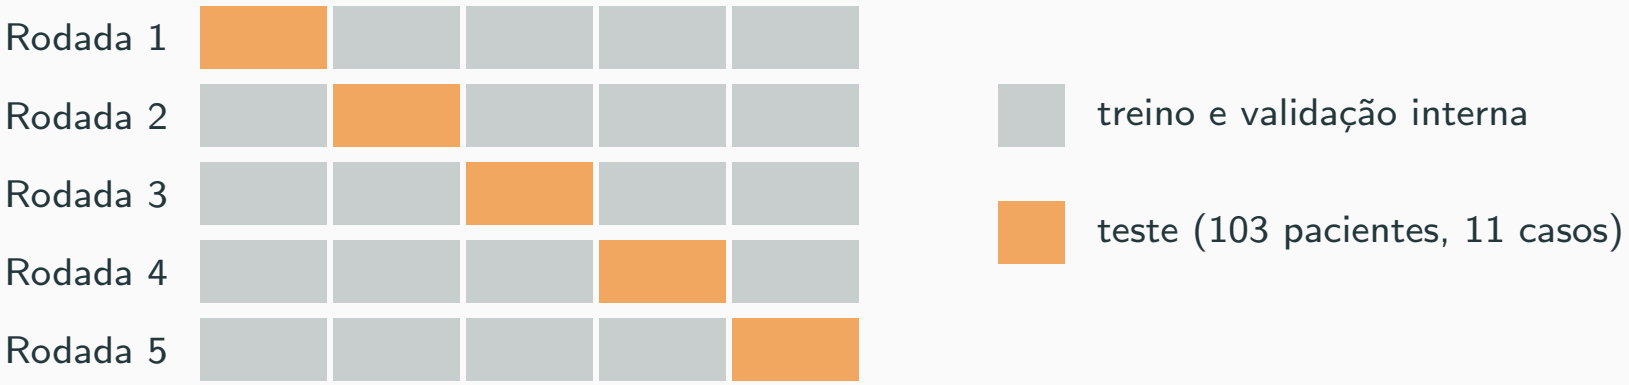
Quatro estágios de dois blocos básicos; a ResNet-50 usa o bloco de gargalo (à direita).

Abordagem 3: representações aprendidas



- Rótulos substitutos: ECG de repouso, ecocardiograma, laboratório e Holter (QRS, FEVE, ondas Q, Pro-BNP...)
- 381 pacientes fora da coorte também entram na etapa 1: eles têm os atributos, mesmo sem o desfecho
- O desfecho só é usado na etapa 2, com um modelo de poucos parâmetros
- Os atributos servem só no treino: na inferência, **basta o Holter**

Protocolo de avaliação



- Validação cruzada em 5 partições, estratificada **por paciente**
- Padronização, escala do sinal e PCA ajustadas só no treino
- Métrica principal: **AUC** das predições fora da partição dos 517 pacientes, com IC 95 % por *bootstrap*
- Sensibilidade e especificidade com limiar de Youden escolhido no treino

Resultados preliminares

Biomarcadores: modelos do protocolo A

Modelo	Variáveis	AUC [IC 95 %]	AP
Clínicas (referência)	6	0,661 [0,577–0,741]	0,233
Marcadores, logística L2	44	0,589 [0,507–0,671]	0,180
Marcadores, logística L1	44	0,585 [0,503–0,666]	0,163
Marcadores, PCA (4) + logística	44	**0,624** [0,535–0,708]	0,232
Marcadores, floresta aleatória	44	0,621 [0,537–0,701]	0,184
Clínicas + marcadores, L2	50	0,672 [0,597–0,745]	0,201
Clínicas + marcadores, L1	50	**0,681** [0,604–0,756]	0,191

- Sozinhos, os marcadores ficam abaixo das seis variáveis clínicas
- Somados a elas, o ganho (+0,020 [−0,047; +0,095]) não é distinguível de zero

AP de referência (acaso) = prevalência = 0,106.

Biomarcadores: o otimismo da seleção

Seleção	Modelo	AUC [IC 95 %]	Δ sobre clínicas
Coorte inteira	4 marcadores	0,627 [0,541–0,710]	—
Coorte inteira	2 marcadores	0,647 [0,559–0,727]	—
Coorte inteira	clínicas + 4 marcadores	0,684 [0,601–0,762]	+0,023
Dentro da partição	4 marcadores	0,580 [0,497–0,660]	—
Dentro da partição	clínicas + 4 marcadores	0,640 [0,553–0,726]	−0,021

- Escolher os marcadores olhando o desfecho de **todos** os pacientes eleva a AUC em cerca de 0,05
- Refeita a seleção só no treino de cada partição, o intervalo inclui o acaso
- Por isso, o modelo final usa marcadores **pré-especificados** pela literatura

Redes convolucionais: capacidade e janela

Rede	Janela	Parâmetros	AUC partições	AUC fora da partição [IC 95 %]
Mínima	2 min	14 425	0,543 ± 0,059	0,523 [0,440–0,612]
Simples	2 min	109 361	0,500 ± 0,067	0,486 [0,402–0,578]
Média	2 min	418 145	0,494 ± 0,119	0,485 [0,400–0,574]
Mínima	10 s	14 425	0,589 ± 0,090	**0,554** [0,467–0,634]
Simples	10 s	109 361	0,509 ± 0,051	0,491 [0,411–0,578]
Média	10 s	418 145	0,495 ± 0,118	0,485 [0,406–0,569]

- Todos os intervalos incluem 0,5: nenhuma rede se distingue do acaso
- A rede menor obteve os maiores valores; mais capacidade não ajudou

Redes residuais: largura e profundidade

Rede	Janela	Parâmetros	AUC fora da partição [IC 95 %]
ResNet-18 mínima	5,12 s	78 169	**0,562** [0,475–0,642]
ResNet-18 reduzida	2 min	1 029 985	0,504 [0,420–0,588]
ResNet-18 completa	2 min	3 976 385	0,508 [0,431–0,588]
ResNet-18 completa	5,12 s	3 976 385	0,492 [0,411–0,577]
ResNet-34	2 min	7 350 721	0,514 [0,429–0,601]
ResNet-50	2 min	16 479 937	0,536 [0,448–0,618]
ResNet-18 + *Transformer*	2 min	—	0,493

- Quadruplicar os parâmetros (ResNet-18 $\rightarrow$ ResNet-50) não mudou o desempenho
- A ResNet-50 tem mais de 53 mil parâmetros por paciente de treino e memoriza o treino nas primeiras épocas

Redes: busca de hiperparâmetros e fusão com clínicas

Modelo	Janela	AUC fora da partição [IC 95 %]
Busca bayesiana (Optuna, 25 tentativas por família)		
Convolucional	1 min	0,556 [0,464–0,647]
Residual	1 min	0,496 [0,411–0,584]
Fusão da ResNet-18 com as seis variáveis clínicas		
Treinamento conjunto	2 min	0,516 [0,433–0,603]
Taxa reduzida no extrator	2 min	**0,579** [0,492–0,669]
Extrator congelado	2 min	0,577 [0,491–0,659]
Só as variáveis clínicas (logística)	—	**0,661** [0,577–0,741]

- A busca não superou as configurações manuais
- Na fusão, o desempenho vem das clínicas; treinar o sinal piora
- Sem a restrição ao ritmo sinusal (703 pacientes), a ResNet-18 chega a 0,575 [0,511–0,642]: aprende a fibrilação atrial, não a morte súbita

Redes: métricas com limiar de Youden

Rede	Janela	AUC	AP	Sens.	Espec.	VPP	VPN
CNN mínima	2 min	0,523	0,139	0,582	0,448	0,111	0,900
CNN simples	2 min	0,486	0,121	0,364	0,645	0,109	0,895
CNN média	2 min	0,485	0,126	0,309	0,688	0,106	0,893
CNN mínima	10 s	0,554	0,132	0,691	0,346	0,112	0,904
CNN simples	10 s	0,491	0,119	0,400	0,530	0,092	0,881
CNN média	10 s	0,485	0,110	0,455	0,485	0,095	0,882
ResNet-18 mínima	5,12 s	0,562	0,160	0,455	0,654	0,135	0,910
ResNet-18 reduzida	2 min	0,504	0,117	0,582	0,437	0,110	0,898
ResNet-18 completa	2 min	0,508	0,121	0,455	0,461	0,091	0,877
ResNet-18 completa	5,12 s	0,492	0,129	0,582	0,442	0,110	0,899
ResNet-34	2 min	0,514	0,122	0,509	0,517	0,112	0,898
ResNet-50	2 min	0,536	0,137	0,455	0,511	0,100	0,887
ResNet-18 + Transformer	2 min	0,493	0,134	0,291	0,703	0,105	0,893
Convolucional, busca	1 min	0,556	0,189	0,509	0,552	0,119	0,904
Residual, busca	1 min	0,496	0,122	0,455	0,565	0,111	0,897
Fusão, treino conjunto	2 min	0,516	0,141	0,418	0,548	0,099	0,888
Fusão, taxa reduzida	2 min	0,579	0,180	0,455	0,673	0,142	0,912
Fusão, extrator congelado	2 min	0,577	0,146	0,727	0,424	0,131	0,929
Fusão, treino conjunto	10 s	0,491	0,113	0,400	0,569	0,100	0,889

Sob classificação aleatória, AP e VPP $\approx$ prevalência (0,106) e VPN $\approx$ 0,894: as redes ficam praticamente nesse nível.

Representações: rede multitarefa e contrastivo

Modelo	AUC [IC 95 %]	Sens.	Espec.
Seis variáveis clínicas	0,661 [0,580–0,743]	0,58	0,67
Rede multitarefa (só Holter)	**0,682** [0,600–0,763]	0,51	0,80
Rede multitarefa + clínicas	**0,702** [0,621–0,780]	0,55	0,74
Valores previstos + clínicas	0,646 [0,557–0,726]	0,49	0,72
Contrastivo	0,590 [0,501–0,677]	0,64	0,45
Contrastivo + clínicas	0,634 [0,551–0,727]	0,64	0,57
Clínicas + FEVE + Pro-BNP	0,705 [0,617–0,780]	0,64	0,68
Clínicas + ecocardiograma	0,720 [0,640–0,789]	0,65	0,64
Clínicas + todos os exames	0,733 [0,656–0,804]	0,71	0,64
Clínicas + todos os exames + rede	0,728 [0,652–0,798]	0,73	0,64

- Sem nenhuma variável clínica, a representação iguala as clínicas; a ResNet-18 treinada no desfecho tinha obtido 0,508
- Com as clínicas, chega ao nível de clínicas + FEVE + Pro-BNP medidos

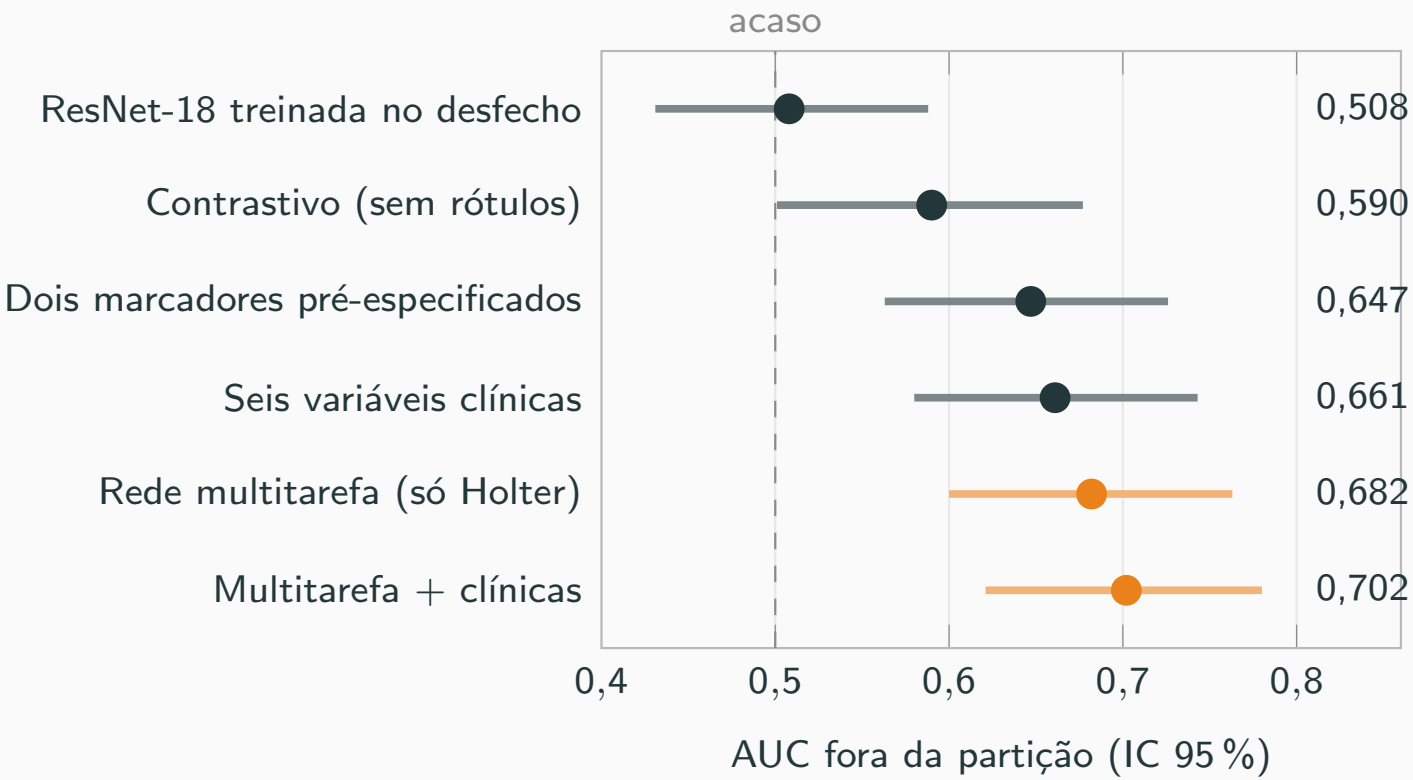
Limiar de Youden escolhido no treino de cada partição.

Aprendizado autossupervisionado

Método (sem rótulos)	AUC [IC 95 %]	O que aconteceu no treino
Extrator aleatório (controle)	0,529 [0,437–0,615]	sem treino
Autoencoder	0,494 [0,413–0,576]	perda praticamente constante
Mascarado	0,555 [0,476–0,649]	perda praticamente constante
Contrastivo	**0,590** [0,501–0,677]	perda de validação em queda
Rede multitarefa	**0,682** [0,600–0,763]	45 atributos clínicos

- Só o contrastivo aprendeu algo além do extrator aleatório: reconhece janelas do mesmo paciente
- Sem rótulos, os padrões encontrados são fracos; com as clínicas, nenhum dos três difere delas
- Orientar a rede por atributos clínicos foi o que fez diferença

Comparação das abordagens



Nas 19 configurações treinadas direto no desfecho, a AUC ficou entre 0,48 e 0,56. Orientada por atributos clínicos, a rede chegou a 0,682 sem usar nenhuma variável clínica.

O que a rede multitarefa aprende

Atributo	Exame	AUC (morte súbita)	Aprendido pela rede
Tamanho do átrio esquerdo	ecocardiograma	**0,701**	$R^2 = 0{,}02$
Pro-BNP	laboratório	**0,682**	$R^2 = 0{,}11$
FEVE	ecocardiograma	**0,650**	$R^2 = 0{,}20$
Ondas Q	ECG	0,567	**AUC = 0,78**
TVNS	Holter	0,550	**AUC = 0,81**
QRS acima de 120 ms	ECG	0,495	**AUC = 0,92**

- Os atributos **elétricos** são bem aprendidos, mas pouco discriminam o desfecho
- Os atributos **estruturais**, que mais discriminam, são os menos aprendidos
- Com todos os exames medidos no modelo, a rede não acrescenta informação (0,733 contra 0,728)

Próximos passos

Plano de trabalho até a defesa

Atividade	Situação
Delimitação da coorte e protocolo de avaliação	concluída
Biomarcadores e redes treinadas no desfecho	concluída
Rede multitarefa e aprendizado autossupervisionado	concluída
Repetir as redes com mais sementes (estabilidade)	planejada
Replicar a coorte de Swee et al. (746 pacientes, derivação Y)	em andamento
Dar mais peso aos atributos estruturais na rede multitarefa	planejada
Escrita final e defesa	em andamento

Referências i

[1] *Caruana Rich*. Multitask Learning // Machine Learning. 1997. 28, 1. 41–75.

[2] *Chen Ting, Kornblith Simon, Norouzi Mohammad, Hinton Geoffrey*. A Simple Framework for Contrastive Learning of Visual Representations // Proceedings of the 37th International Conference on Machine Learning. 119. 2020. 1597–1607. (Proceedings of Machine Learning Research).

[3] *He Kaiming, Zhang Xiangyu, Ren Shaoqing, Sun Jian*. Deep residual learning for image recognition // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016. 770–778.

[4] *Kapoor Sayash, Narayanan Arvind*. Leakage and the reproducibility crisis in machine-learning-based science // Patterns. 2023. 4, 9. 100804.

[5] *Kim Ju Youn, Kim Kyung Geun, Joo Sunghoon, Chang Mineok, Kim Juwon, Park Kyoung-Min, On Young Keun, Kim June Soo, Lee Young Soo, Park Seung-Jung*. Deep Learning-Based Risk Assessment and Prediction of Cardiac Outcomes Using Single-Lead 24-Hour Holter-ECG in Patients with Heart Failure or Myocardial Infarction // Journal of Clinical Medicine. 2025. 14, 20. 7209.

Referências ii

[6] *LeCun Yann, Bottou Léon, Bengio Yoshua, Haffner Patrick*. Gradient-based learning applied to document recognition // Proceedings of the IEEE. 1998. 86, 11. 2278–2324.

[7] *Makowski Dominique, Pham Tam, Lau Zen J., Brammer Jan C., Lespinasse François, Pham Hung, Schölzel Christopher, Chen S. H. Annabel*. NeuroKit2: A Python toolbox for neurophysiological signal processing // Behavior Research Methods. 2021. 53, 4. 1689–1696.

[8] *Martín-Yebra Alba, Luna Antoni Bayés de, Vázquez Rafael, Caminal Pere, Laguna Pablo, Martínez Juan Pablo*. The MUSIC Database: Sudden Cardiac Death in Heart Failure Patients // Computing in Cardiology. 51. 2024.

[9] *Martin-Yebra Alba, Martínez Juan Pablo, Laguna Pablo*. MUSIC (Sudden Cardiac Death in Chronic Heart Failure) (version 1.0.1). 2025. RRID:SCR_007345.

[10] *Ramírez Julia, Orini Michele, Mincholé Ana, Monasterio Violeta, Cygankiewicz Iwona, Luna Antoni Bayés de, Martínez Juan Pablo, Laguna Pablo, Pueyo Esther*. Sudden cardiac death and pump failure death prediction in chronic heart failure by combining ECG and clinical markers in an integrated risk model // PLoS ONE. 2017. 12, 10. e0186152.

Referências iii

[11] *Swee Steven, Adam Irsyad, Zheng Erika Yilin, Ji Ethan, Wang Ding, Speier William, Hsu Jeffrey, Chang Kai-Wei, Shivkumar Kalyanam, Ping Peipei*. Multimodal Integration of Ambulatory ECG and Clinical Features for Sudden Cardiac Death and Pump Failure Death Prediction // medRxiv. 2026.

Obrigado!

Daniel Oliveira dos Santos

MDCC/UFC

Apoio: CAPES — Código de Financiamento 001